

Билеты к экзамену по DL

Марк Блуменау

1 октября 2026 г.

Предисловие

В случае успешной (дан ответ хотя бы на половину) сдачи «Основных понятий курса», студенту случайным образом достаётся билет из представленных ниже. За него можно получить ещё до 4 баллов. Правильные ответы к этим вопросам необходимо расписывать самим. Подразумевается, что ответ на эти вопросы продемонстрирует глубокое понимание тем курса, а не будет сборником ответов на вопросы «Основных понятий курса». Подготовьте ручку и листок бумаги, возможно, удобнее рисовать для ответа на вопросы. Принимающий может спросить дополнительный вопрос(-ы) в рамках билета (то есть в рамках этих 4 баллов).

Для получения оценки 9–10 студенту могут задать дополнительные вопросы сверх билета. Это могут быть как вопросы из списка ниже, так и задачи/вопросы «на подумать» от проверяющего. Их может не быть в списке ниже. Гарантируется, что дополнительные вопросы будут по тем темам, которые были освещены в курсе.

Вторая часть экзамена длится до 12 минут суммарно.

Вопросы

1. Линейный слой

Что такое линейный (полносвязный) слой? Напишите формулу. Сформулируйте Универсальную теорему аппроксимации. Что она гарантирует, а что нет? Зачем нужна нелинейность между линейными слоями? Какие нелинейности вам известны? В чём их плюсы и минусы? Как вычисляется число обучаемых параметров в линейном слое? Как работает backpropagation? Покажите на примере маленькой полносвязной нейросети, расписав формулы.

2. Градиентный спуск и loss-функции

Опишите основные виды градиентного спуска (GD, SGD, mini-batch). Зачем нужен momentum? Что такое Adam и зачем в нём коррекция смещения (bias correction)? Чем AdamW отличается от Adam с L_2 -регуляризацией? Какие loss-функции применяются для задач классификации и регрессии? Как влияет выбор lr и использование lr-scheduler на процесс обучения?

3. Инициализация

Почему важна правильная инициализация весов в нейронных сетях? Опишите распространённые методы инициализации (Xavier, He) и объясните их принципы. Для каких функций активации подходит каждый из них? Как неправильная инициализация может привести к затуханию или взрыву градиентов? Можно ли инициализировать веса константой? Что тогда произойдёт?

4. Dropout, BatchNorm

Объясните принцип работы Dropout в режимах train и eval. Запишите формулы. Что такое BatchNorm и как он влияет на процесс обучения? Как он себя ведёт в train и eval режиме? По каким осям считаются статистики для полносвязного и для свёрточного слоя? Что делать, если batch size очень маленький? Нужно ли нормализовать данные перед подачей их в нейросеть? Это справедливо только для полносвязных сетей или применимо и к CNN?

5. Операция свёртки в CNN

Запишите формулу свёрточного слоя, укажите, как рассчитывается число параметров (с учётом bias и без bias). Как оно меняется при $\text{groups} > 1$? Как вычисляется количество операций умножения при свёртке для заданных размеров входного и выходного тензора? Как stride, padding и dilation влияют на размер выходного тензора? Что такое поле восприятия (receptive field)? Как его считать?

6. Pooling и padding

Какие виды pooling вам известны? Зачем нам pooling? Чем pooling отличается от свёртки со stride

2? Какие существуют виды padding и как они влияют на размер выходного тензора? Приведите примеры, где данные техники применяются для улучшения архитектуры сети.

7. Архитектуры свёрточных нейронных сетей

Какие известные архитектуры CNN вы знаете (AlexNet, VGG, Inception, ResNet)? Можно нарисовать схематично. Запишите формулу остаточного блока ResNet. Какую проблему обучения глубоких сетей решают residual-связи? Какие преимущества и недостатки различных архитектур? Какую архитектуру вы бы предпочли использовать сейчас?

8. Перенос знаний и fine-tuning в CNN

Что такое transfer learning и как его применять в задачах компьютерного зрения? Объясните понятие fine-tuning и приведите пример его использования. Что значит «заморозить» веса нейронной сети? Какие особенности следует учитывать при адаптации предобученной модели к новой задаче? Как выбор замораживаемых слоёв зависит от размера датасета и его близости к исходному домену?

9. Аугментация данных в задачах компьютерного зрения

Какую роль играет аугментация данных в обучении CNN? Какие виды аугментаций наиболее распространены и в каких областях их использование может быть ограничено? Приведите примеры, расскажите про плюсы и минусы подхода.

10. Детекция

Объясните, в чём разница между задачами классификации, сегментации и детекции в компьютерном зрении. Расскажите о развитии архитектур для задач детекции (R-CNN, Fast R-CNN, Faster R-CNN, YOLO). Как работает Non-Maximum Suppression? Что такое AP и mAP? Как предсказания сопоставляются с ground truth и что при этом считается TP, FP и FN?

11. Сегментация

Объясните, в чём разница между задачами классификации, сегментации и детекции в компьютерном зрении. Что такое IoU и как оно используется для оценки качества сегментации? Расскажите об отличиях semantic и instance сегментации. Опишите архитектуру UNet и идею Mask R-CNN. Какую функцию потерь вы бы выбрали при сильном дисбалансе классов на маске?

12. Трекинг

Что такое object tracking и почему это сложная задача? Из каких компонентов состоит типичный трекер (например, SORT)? Опишите идею метрики HOTA: что измеряют DetA и AssA и как они объединяются? Как на этих компонентах отразится то, что трекер часто путает id объектов при пересечении их траекторий?

13. Идентификация

Объясните, в чём разница между задачами классификации и идентификации в компьютерном зрении. Почему задачу идентификации не стоит решать классификацией? Как классификатор, обученный на известных идентичностях, можно использовать для новых (например, в DeepFace)? Какие функции потерь вам известны для этой задачи? Как устроены модели для решения этого типа задач?

14. Few-shot и zero-shot обучение

Что такое few-shot обучение в постановке N -way K -shot? Что такое support set и query set? Что такое мета-обучение и почему в нём обучающими примерами выступают целые задачи? В чём идея MAML? Что такое zero-shot обучение? Опишите идею CLIP и то, как с его помощью выполняется zero-shot классификация. Как добавить новый класс в классификатор на основе CLIP без дообучения?

15. Рекуррентные нейронные сети (RNN)

Что такое RNN и как они работают? Запишите формулу обновления скрытого состояния. В чём заключается мотивация использования RNN для работы с последовательными данными? Какие проблемы возникают при обучении RNN (затухание/взрыв градиентов) и как их можно решать? Приведите примеры использования RNN в задачах классификации и регрессии на текстовых данных.

16. LSTM и GRU

Объясните, в чём заключаются слабые места стандартных RNN и как LSTM/GRU решают эти проблемы. Расскажите о структуре LSTM и основных компонентах (ячейка памяти, входной/выходной и забывающий гейты). Почему LSTM ослабляет, но не устраняет полностью проблему затухания градиента? Сравните LSTM и GRU, в чём основные отличия? Запишите формулы для этих слоёв или хотя бы назовите основные компоненты и сравните количество обучаемых параметров.

17. **Эмбединги для текстовых данных**

Что такое эмбединги и зачем они нужны в обработке текстов? Опишите модель word2vec (CBOW и Skip-gram), её преимущества и недостатки. Зачем нужен negative sampling? Как измерять близость эмбедингов? Как эмбединги влияют на качество обработки естественного языка? Как обучить свои эмбединги в PyTorch?

18. **Generative Adversarial Networks (GAN)**

Что такое GAN и из каких компонентов состоит эта архитектура? Опишите роль каждой компоненты и сформулируйте задачу обучения GAN как минимаксную оптимизационную проблему. Какие основные трудности возникают при обучении GAN? Что происходит, если дискриминатор слишком быстро становится идеальным? В каких случаях GAN модель подходит лучше других генеративных моделей?

19. **Autoencoder и Variational Autoencoder (AE/VAE)**

Что такое автоэнкодер и какие задачи он решает? В чём принципиальное отличие вариационного автоэнкодера от обычного автоэнкодера? Что такое reparameterization trick? Запишите ELBO. Какую роль играет KL-дивергенция в функции потерь VAE? Что произойдёт, если её убрать? В чём преимущества и недостатки данной модели?

20. **Diffusion Models**

Опишите общую идею диффузионных моделей. Как формулируются прямой и обратный процессы? Почему обучение диффузионных моделей часто сводится к задаче предсказания шума? Какие ещё параметризационные варианты вам известны? В чём основные преимущества диффузионных моделей? Какие недостатки у этого подхода? Зачем нам scheduler?

21. **Normalizing Flows (NF)**

Что такое normalizing flows и какая идея лежит в основе этого подхода? Как используется формула замены переменных для вычисления правдоподобия? Какие требования накладываются на преобразования в normalizing flows? Почему обычный полносвязный слой с ReLU не подходит? Опишите (формулы необязательны) RealNVP. Сравните normalizing flows с остальными моделями.

22. **Механизм Attention**

Что такое механизм внимания (attention) и какую проблему он решает в моделях для работы с последовательными данными? Опишите общую идею query-key-value и запишите формулу attention. Зачем делить на $\sqrt{d_k}$? Как attention влияет на интерпретируемость моделей? Можно ли считать веса внимания объяснением предсказания? Приведите примеры задач, в которых использование attention даёт существенный выигрыш по сравнению с моделями без внимания.

23. **Transformers**

Опишите архитектуру Transformer. В чём разница между self-attention и cross-attention? Зачем нужны несколько голов внимания? Что делает masked self-attention и как он реализуется? Почему Transformer не использует рекуррентные связи? Как кодируется информация о порядке токенов? Чем GPT отличается от BERT? Чем эта архитектура лучше RNN?

24. **Стратегии декодирования**

Как языковая модель генерирует текст авторегрессионно? Опишите greedy search и beam search, их плюсы и минусы. Опишите temperature, top-k и top-p sampling. Как эти стратегии влияют на компромисс между связностью и разнообразием текста? В каких задачах вы бы выбрали beam search, а в каких сэмплирование?

25. **Low-Rank Adaptation (LoRA)**

Что такое LoRA и для каких задач она используется? В чём заключается идея low-rank аппроксимации при дообучении больших языковых моделей? Какие преимущества LoRA имеет по сравнению с полным fine-tuning и adapter-based подходами? Как LoRA влияет на количество обучаемых параметров и потребление памяти? Почему экономия памяти заметно меньше, чем сокращение числа обучаемых параметров?

26. **Постановка и воспроизводимость экспериментов**

Зачем нужны train, validation и test выборки? Что такое утечка данных и как она может возникнуть при предобработке? Как корректно сравнить две архитектуры или два набора гиперпараметров? Как интерпретировать результат, если улучшение меньше разброса метрики между запусками с разными seed? Какие источники случайности есть в обучении нейросети и как их зафиксировать в PyTorch? Всегда ли достижим полный детерминизм на GPU?