

Основные понятия курса

Марк Блуменау

20 января 2026 г.

Предисловие

Знание ответов на данные вопросы и возможность ответить на 4 из них за 3 минуты гарантирует студенту оценку 4 'удовл.' за экзамен. Ответы приведены такие, которые точно достаточны, но, естественно, принимается любая верная формулировка и формула. В случае опечаток незамедлительно сообщите @markblumenu.

Вопросы

1. Виды градиентного спуска и функций потерь

1. **Что такое mini-batch стохастический градиентный спуск?**

Ответ: Обновление параметров модели на основе mini-batch, а не полного набора данных.

2. **Какова идея лежит в основе градиентного спуска?**

Ответ: Итеративное изменение параметров для минимизации функции потерь.

3. **Что такое MSE?**

Ответ: $MSE = \frac{1}{n} \sum (y_{\text{pred}} - y_{\text{true}})^2$.

4. **Какую функцию потерь можно использовать для обучения в задаче классификации?**

Ответ: Кросс-энтропия. (Любые другие корректные ответы принимаются)

5. **Что такое оптимизатор Adam?**

Ответ: Комбинирует методы AdaGrad и RMSProp для адаптивного шага обучения.

6. **Какую проблему пытается решить моментум в градиентном спуске?**

Ответ: Проблему застревания в неглубоких локальных минимумах.

7. **Каким методом вычисляются градиенты в нейросетях?**

Ответ: Методом обратного распространения ошибки.

8. **Как в PyTorch называется параметр для регуляризации весов?**

Ответ: Weight decay.

2. Linear, Dropout + Batch Normalization

1. **Что такое линейный слой (Fully Connected Layer)?**

Ответ: Это слой, который описывается формулой: $y = xA^T + b$.

2. **Что такое Dropout (кратко)?**

Ответ: Случайное отключение нейронов для предотвращения переобучения.

3. **Что такое Batch Normalization (кратко)?**

Ответ: Масштабирование батча на входе в слой так, что матожидание 0, а дисперсия 1.

4. **Какие параметры используются в Batch Normalization?**

Ответ: Параметры γ (масштаб) и β (смещение).

5. **Какова общая цель использования Dropout и BatchNorm?**

Ответ: Улучшение обобщения и стабильности обучения модели.

6. **Какое количество параметров у Linear слоя?**

Ответ: $(\text{Количество входов} + 1) \cdot \text{количество выходов}$.

7. **Как работает Dropout с точки зрения формул?**

Ответ: $y_{\text{dropout}} = (r \odot y)$, где $r \sim \text{Bernoulli}(p)$.

8. **Запишите формулы для вычисления Batch Normalization.**

Ответ:

$$\mu_B = \frac{1}{m} \sum_i x_i, \quad \sigma_B^2 = \frac{1}{m} \sum_i (x_i - \mu_B)^2, \quad \hat{x}_i = \frac{x_i - \mu_B}{\sqrt{\sigma_B^2 + \varepsilon}}, \quad y_i = \gamma \hat{x}_i + \beta.$$

9. **Какую роль играет функция активации ReLU?**

Ответ: Вводит нелинейность: $f(x) = \max(0, x)$.

10. **Почему нужна нелинейность между слоями?**

Ответ: Использование двух линейных слоев подряд эквивалентно использованию одного линейного слоя.

11. **Что такое Универсальная теорема аппроксимации? (Цыбенко)**

Ответ: Линейная нейросеть с одним скрытым слоем может аппроксимировать любую непрерывную функцию многих переменных с любой точностью.

3. Операции в CNN

1. **Что такое свёрточный слой в CNN?**

Ответ: Выполняет операцию свёртки изображения с фильтрами для извлечения признаков.

2. **Сколько параметров в Conv2d слое?**

Ответ: $K \cdot K \cdot C_{in} \cdot C_{out} + C_{out}$, где K - размер ядра, C - количество каналов.

3. **Сколько умножений в Conv2d слое?**

Ответ: $H \cdot W \cdot C_{out} \cdot (K \cdot K \cdot C_{in})$, где K - размер ядра, C - количество каналов, H и W - высота и ширина выходного тензора.

4. **Какова роль ядра свёртки?**

Ответ: Выделяет локальные паттерны через взвешенное суммирование пикселей.

5. **Что такое stride (шаг) в свёрточном слое?**

Ответ: Количество пикселей, на которое сдвигается фильтр при свёртке.

6. **Что такое padding в свёрточном слое?**

Ответ: Добавление дополнительных пикселей для сохранения размерности.

7. **Что делает операция pooling?**

Ответ: Уменьшает размерность, беря заданную функцию в заданном окне.

8. **Как вычисляется размер выходного тензора свёрточного слоя?**

Ответ: $O = \frac{W-F+2P}{S} + 1$, где W — размер входа, F — размер ядра, P — паддинг, S — шаг.

9. **Запишите формулу свёрточной операции для изображения.**

Ответ:

$$\text{Im}^{\text{out}}(x, y, t) = \sum_{i=-d}^d \sum_{j=-d}^d \sum_{c=1}^c (K_t(i, j, c) \text{Im}^{\text{in}}(x + i, y + j, c) + b_t)$$

10. **Как изменяется размерность при max pooling?**

Ответ: Размер = $\frac{W-F}{S} + 1$, где F — размер окна, S — шаг pooling.

11. **Что такое zero-padding и для чего он применяется?**

Ответ: Добавление нулевых элементов по границам для сохранения размерности после свёртки.

4. Архитектуры CNN

1. **Чем характеризуется архитектура VGG?**

Ответ: Глубокая сеть с последовательными свёрточными слоями и небольшими фильтрами.

2. **Запишите формулу остаточного блока (residual block) в ResNet.**

Ответ: $y = F(x, \{W_i\}) + x$.

3. **Что такое ResNet?**

Ответ: Сеть с остаточными (residual) связями, позволяющими строить более глубокие модели.

5. Задачи компьютерного зрения (CV tasks)

1. **Что такое задача классификации изображений?**

Ответ: Определение категории объекта на изображении.

2. **Что такое задача детекции объектов?**

Ответ: Выделение и локализация объектов с указанием их координат и категории.

3. **Что такое сегментация изображений?**

Ответ: Разделение изображения на области, соответствующие различным объектам.

4. **Запишите формулу для вычисления IoU в детекции объектов.**

Ответ: $\text{IoU} = \frac{\text{area}(\text{intersection})}{\text{area}(\text{union})}$.

5. **Как применяется Non-Maximum Suppression (NMS) в обнаружении объектов?**

Ответ: Выбираются боксы с наибольшей уверенностью, удаляя сильно перекрывающиеся с ними.

6. **Как формализуется задача сегментации изображений?**

Ответ: Минимизируется функция $L(\text{mask}_{\text{pred}}, \text{mask}_{\text{true}})$, например, dice loss.

7. **Как определяется метрика mAP для оценки детекции?**

Ответ: Усреднением AP по классам. $\text{mAP} = \frac{1}{N} \sum \text{AP}_i$, где AP — площадь под кривой precision-recall.

6. Эмбединги

1. Что такое эмбединги?

Ответ: Представление дискретных данных в виде плотных векторных пространств.

2. Что такое cosine similarity для эмбедингов?

Ответ: $\cos(\theta) = \frac{A \cdot B}{\|A\| \cdot \|B\|}$.

3. Как выглядит softmax-функция для нормализации эмбедингов?

Ответ: $\text{softmax}(z_i) = \frac{\exp(z_i)}{\sum_j \exp(z_j)}$.

7. RNN, LSTM, GRU

1. Что такое RNN?

Ответ: Рекуррентная нейронная сеть, обрабатывающая последовательные данные с сохранением состояния (в так называемом скрытом состоянии).

2. Что такое LSTM?

Ответ: RNN с ячейками памяти и гейтами для контроля потока информации, предотвращающих затухание градиентов.

3. Что такое GRU?

Ответ: Упрощённая версия LSTM с двумя гейтами (обновления и сброса).

4. Запишите формулу обновления скрытого состояния в стандартном RNN.

Ответ:

$$h_t = \tanh(x_t W_{ih}^T + b_{ih} + h_{t-1} W_{hh}^T + b_{hh})$$

8. Генеративные модели

1. Что называют латентным пространством?

Ответ: Это скрытое представление данных, где компактно хранятся их ключевые особенности.

2. Что такое автоэнкодер и какова его структура?

Ответ: Автоэнкодер - сеть, которая сжимает данные в скрытое пространство и восстанавливает обратно. Он состоит из энкодера и декодера.

3. Как работает декодер в автоэнкодере?

Ответ: Он берёт латентный вектор и преобразует его обратно в изображение.

4. Что такое генеративно-сопоставительная сеть (GAN)?

Ответ: Это модель, где генератор создает изображения, а дискриминатор пытается отличить их от настоящих.

5. Объясните термин mode collapse. Для какого семейства генеративных моделей свойственен mode collapse?

Ответ: Mode collapse - генератор начинает выдавать очень ограниченное разнообразие результатов. Характерно для GAN.

6. Почему GAN часто нестабилен при обучении?

Ответ: Из-за соревновательного процесса и чувствительности к балансу между сетями.

7. Что такое диффузионная модель?

Ответ: Модель, учившаяся пошагово удалять шум, восстанавливая изображение.

8. **Как организован процесс добавления шума на изображение при обучении диффузионной модели?**
Ответ: Шум добавляется постепенно, приближая картинку к чистому шуму.
9. **Что такое нормализационные потоки?**
Ответ: Обратимые преобразования, моделирующие сложные распределения данных.
10. **Каковы основные ограничения нормализационных потоков?**
Ответ: Они вычислительно тяжёлые и требуют строгой обратимости.
11. **В чём недостаток диффузионных моделей с точки зрения вычислительных затрат?**
Ответ: Им нужно много шагов, что делает генерацию медленной.

9. Трансформеры

1. **Что такое механизм внимания?**
Ответ: Attention - это способ выделить самые важные части входа для текущего шага обработки.
2. **Что означают термины Query, Key, Value?**
Ответ: Это три представления токенов, через которые считается внимание.
- Query (запрос) - что я ищу?
 - Key (ключ) - что я предлагаю?
 - Value (значение) - что я получу, если сопоставление подошло?
3. **Как вычисляется attention score?**
Ответ:
- $$Attention(Q, K, V) = softmax(\frac{QK^T}{\sqrt{d_k}})V$$
4. **Почему несколько голов внимания повышают точность трансформерных моделей (по сравнению с одной головой внимания)?**
Ответ: Потому что разные головы фокусируются на разных закономерностях в данных.
5. **Что делает position encoding и зачем он нужен?**
Ответ: Он добавляет информацию о позиции токенов, которой обычному трансформеру по умолчанию не хватает.
6. **Что делает masked self-attention?**
Ответ: Запрещает смотреть на будущие токены при генерации.
7. **Чем GPT отличается от BERT?**
Ответ: GPT - Decoder, BERT - Encoder.
8. **Что такое LoRA?**
Ответ: LoRA (Low-Rank Adaptation) - это метод дообучения больших нейросетей, при котором основные веса модели замораживаются, а обучение идёт только по небольшим низкоранговым добавкам.