

Основные понятия курса

Марк Блуменау

1 октября 2026 г.

Предисловие

Знание ответов на данные вопросы и возможность ответить на 4 из них за 3 минуты гарантирует студенту оценку 4 «удовл.» за экзамен. Ответы приведены такие, которые точно достаточны, но, естественно, принимается любая верная формулировка и формула. В случае опечаток незамедлительно сообщите @markblumenau.

Вопросы

1. Виды градиентного спуска и функций потерь

1. Что такое mini-batch стохастический градиентный спуск?

Ответ: Обновление параметров модели по градиенту, усреднённом по небольшой случайной подвыборке (mini-batch), а не по всему набору данных.

2. Какая идея лежит в основе градиентного спуска?

Ответ: Итеративное изменение параметров в направлении антиградиента для минимизации функции потерь.

3. Что такое MSE?

Ответ: $MSE = \frac{1}{n} \sum_i (y_{\text{pred},i} - y_{\text{true},i})^2$.

4. Какую функцию потерь можно использовать для обучения в задаче классификации?

Ответ: Кросс-энтропию: $L = - \sum_c q_c \log p_c$, где $p = \text{softmax}(z)$, q — истинное (обычно one-hot) распределение. (Любые другие корректные ответы принимаются)

5. Что такое оптимизатор Adam?

Ответ: Адаптивный оптимизатор: хранит экспоненциальные скользящие средние градиента m_t и его квадрата v_t и делает шаг $\theta_t = \theta_{t-1} - \eta m_t / (\sqrt{v_t} + \epsilon)$.

6. Чем AdamW отличается от Adam?

Ответ: В AdamW weight decay применяется к весам напрямую ($\theta \leftarrow \theta - \eta \lambda \theta$), а не добавляется к градиенту как L_2 -регуляризация, поэтому не масштабируется адаптивным шагом.

7. Какую проблему пытается решить моментум в градиентном спуске?

Ответ: Накапливая среднее градиентов, ускоряет движение вдоль устойчивого направления и гасит осцилляции (например, в «оврагах»); помогает проходить плато и неглубокие локальные минимумы.

8. **Каким методом вычисляются градиенты в нейросетях?**

Ответ: Методом обратного распространения ошибки (backpropagation), то есть применением правила дифференцирования сложной функции.

9. **Как в PyTorch называется параметр для регуляризации весов?**

Ответ: `weight_decay`.

2. Linear, инициализация, Dropout + Batch Normalization

1. **Что такое линейный слой (Fully Connected Layer)?**

Ответ: Это слой, который описывается формулой: $y = xA^T + b$.

2. **Какое количество параметров у Linear слоя?**

Ответ: $(\text{Количество входов} + 1) \cdot \text{количество выходов}$.

3. **Почему нужна нелинейность между слоями?**

Ответ: Композиция линейных слоёв — снова линейное отображение, поэтому два линейных слоя подряд эквивалентны одному.

4. **Какую роль играет функция активации ReLU?**

Ответ: Вводит нелинейность: $f(x) = \max(0, x)$.

5. **Что такое Универсальная теорема аппроксимации? (Цыбенко)**

Ответ: Нейросеть с одним скрытым слоем достаточной ширины и сигмоидальной функцией активации может приблизить любую непрерывную функцию на компакте в $\mathbb{R}^n$ с любой точностью. Теорема не говорит, как найти такую сеть и какой ширины она будет.

6. **Зачем нужна правильная инициализация весов и что предлагают методы Xavier и He?**

Ответ: Неудачная инициализация приводит к затуханию или взрыву активаций и градиентов. Xavier: $\text{Var}(w) = 2/(n_{in} + n_{out})$, для tanh/sigmoid. He: $\text{Var}(w) = 2/n_{in}$, для ReLU.

7. **Что произойдёт, если инициализировать все веса сети одной и той же константой?**

Ответ: Нейроны одного слоя будут получать одинаковые градиенты и останутся одинаковыми (симметрия не нарушится), то есть слой будет работать как один нейрон.

8. **Как работает Dropout в режимах train и eval?**

Ответ: В train каждый нейрон зануляется с вероятностью p , а оставшиеся домножаются на $1/(1 - p)$: $y = (r \odot x)/(1 - p)$, $r_i \sim \text{Bernoulli}(1 - p)$. В eval dropout отключён: $y = x$.

9. **Что такое Batch Normalization (кратко)?**

Ответ: Нормализация активаций по батчу к нулевому среднему и единичной дисперсии с последующим обучаемым масштабом γ и сдвигом β .

10. **Запишите формулы для вычисления Batch Normalization. Чем отличаются train и eval?**

Ответ:

$$\mu_B = \frac{1}{m} \sum_i x_i, \quad \sigma_B^2 = \frac{1}{m} \sum_i (x_i - \mu_B)^2, \quad \hat{x}_i = \frac{x_i - \mu_B}{\sqrt{\sigma_B^2 + \varepsilon}}, \quad y_i = \gamma \hat{x}_i + \beta.$$

В train используются статистики текущего батча и обновляются running mean/var, в eval — накопленные running mean/var.

11. **Какова общая цель использования Dropout и BatchNorm?**

Ответ: Улучшение обобщения и стабильности обучения модели.

12. **Нужно ли нормализовать входные данные перед подачей в нейросеть?**

Ответ: Обычно да, это ускоряет и стабилизирует обучение — и для полносвязных сетей, и для CNN (по каналам). Статистики считаются только по train; для предобученной модели используют ту же нормализацию, что и при её обучении.

3. Операции в CNN

1. **Что такое свёрточный слой в CNN?**

Ответ: Слой, который сворачивает вход с набором обучаемых фильтров (взвешенное суммирование по локальной окрестности) для извлечения признаков.

2. **Сколько параметров в Conv2d слое?**

Ответ: $K \cdot K \cdot C_{in} \cdot C_{out} + C_{out}$, где K — размер ядра, C — количество каналов.

3. **Сколько умножений в Conv2d слое?**

Ответ: $H \cdot W \cdot C_{out} \cdot (K \cdot K \cdot C_{in})$, где K — размер ядра, C — количество каналов, H и W — высота и ширина выходного тензора.

4. **Что такое stride (шаг) в свёрточном слое?**

Ответ: Количество пикселей, на которое сдвигается фильтр при свёртке.

5. **Что такое padding в свёрточном слое?**

Ответ: Добавление дополнительных пикселей по краям входа, чтобы контролировать (например, сохранить) размер выхода.

6. **Что делает операция pooling?**

Ответ: Уменьшает пространственный размер, применяя заданную функцию (max, mean) в скользящем окне.

7. **Как вычисляется размер выходного тензора свёрточного слоя?**

Ответ: $O = \left\lfloor \frac{W - K_{eff} + 2P}{S} \right\rfloor + 1$, где W — размер входа, $K_{eff} = D(K - 1) + 1$ — эффективный размер ядра (D — dilation), P — паддинг, S — шаг. Для pooling формула та же.

8. **Запишите формулу свёрточной операции для изображения.**

Ответ:

$$\text{Im}^{out}(x, y, t) = \sum_{i=-d}^d \sum_{j=-d}^d \sum_{c=1}^C K_t(i, j, c) \text{Im}^{in}(x + i, y + j, c) + b_t.$$

9. **Что такое zero-padding и для чего он применяется?**

Ответ: Добавление нулевых элементов по границам для сохранения размерности после свёртки.

10. **Что такое рецептивное поле (поле восприятия)?**

Ответ: Область входного изображения, от которой зависит значение данного нейрона; растёт с глубиной сети, размером ядра, stride и dilation.

11. **Что делает dilation в свёрточном слое?**

Ответ: Раздвигает элементы ядра, увеличивая рецептивное поле без увеличения числа параметров.

4. Архитектуры CNN, transfer learning и аугментация

1. **Чем характеризуется архитектура VGG?**

Ответ: Глубокая сеть с последовательными свёрточными слоями и небольшими (3×3) фильтрами.

2. **Запишите формулу остаточного блока (residual block) в ResNet.**

Ответ: $y = F(x, \{W_i\}) + x$.

3. **Что такое ResNet?**

Ответ: Сеть с остаточными (residual) связями, которые облегчают прохождение градиента и позволяют обучать гораздо более глубокие модели.

4. **Что такое transfer learning?**

Ответ: Использование модели, предобученной на одной (обычно большой) задаче, как инициализации или экстрактора признаков для другой задачи.

5. **Что значит «заморозить» веса нейросети?**

Ответ: Отключить обновление весов части слоёв при обучении (`requires_grad = False`).

6. **Зачем нужна аугментация данных?**

Ответ: Увеличивает разнообразие обучающей выборки и работает как регуляризация, снижая переобучение. Примеры: flip, поворот, crop, изменение цвета.

5. Задачи компьютерного зрения (CV tasks)

1. **Что такое задача классификации изображений?**

Ответ: Определение категории объекта на изображении.

2. **Что такое задача детекции объектов?**

Ответ: Выделение и локализация объектов с указанием их координат (bounding box) и категории.

3. **Что такое сегментация изображений?**

Ответ: Отнесение каждого пикселя изображения к классу (semantic) или к конкретному объекту (instance).

4. **Запишите формулу для вычисления IoU.**

Ответ:
$$\text{IoU} = \frac{\text{area}(\text{intersection})}{\text{area}(\text{union})}.$$

5. **Как применяется Non-Maximum Suppression (NMS) в обнаружении объектов?**

Ответ: Выбираются боксы с наибольшей уверенностью, а сильно перекрывающиеся с ними (IoU выше порога) удаляются.

6. **Как формализуется задача сегментации изображений?**

Ответ: Минимизируется функция $L(\text{mask}_{pred}, \text{mask}_{true})$, например попиксельная cross-entropy или dice loss.

7. **Как вычисляется AP в детекции?**

Ответ: Предсказания сортируются по уверенности; предсказание — TP, если его IoU с ещё не сопоставленным ground truth того же класса не меньше порога, иначе FP. По ним строится кривая precision-recall, AP — площадь под ней.

8. **Как определяется метрика mAP для оценки детекции?**

Ответ: Усреднением AP по классам: $mAP = \frac{1}{N} \sum_{i=1}^N AP_i$ (в COCO — ещё и по порогам IoU от 0.5 до 0.95).

9. **Чем идентификация отличается от классификации?**

Ответ: Число идентичностей заранее неизвестно, и новые должны распознаваться без переобучения, поэтому вместо softmax-выхода сравнивают эмбединги объектов по метрике близости.

10. **Что такое Triplet Loss?**

Ответ: $L = \max(0, d(a, p) - d(a, n) + \text{margin})$, где a — anchor, p — объект того же класса, n — объект другого класса.

11. **Что такое object tracking?**

Ответ: Задача сопровождения объектов между кадрами видео с сохранением их идентичности (id).

12. **Из каких компонентов состоит типичный трекер (например, SORT)?**

Ответ: Детектор, предсказание движения (фильтр Калмана), сопоставление треков с детекциями (венгерский алгоритм по IoU), обновление треков.

13. **Какова идея метрики НОТА?**

Ответ: Объединяет точность детекции (DetA) и точность ассоциации id между кадрами (AssA): $NOTA = \sqrt{\text{DetA} \cdot \text{AssA}}$ (с усреднением по порогам IoU).

6. Эмбединги, few-shot и zero-shot

1. **Что такое эмбединги?**

Ответ: Представление дискретных объектов (слов, токенов, изображений) в виде плотных векторов.

2. **Что такое cosine similarity для эмбедингов?**

Ответ: $\cos(\theta) = \frac{A \cdot B}{\|A\| \cdot \|B\|}$.

3. **Как выглядит softmax-функция и для чего она применяется?**

Ответ: $\text{softmax}(z_i) = \frac{\exp(z_i)}{\sum_j \exp(z_j)}$; переводит вектор логитов в распределение вероятностей.

4. **Что такое few-shot обучение в постановке N-way K-shot?**

Ответ: Нужно различать N новых классов, имея по K размеченных примеров каждого (support set); качество оценивается на query set.

5. **Что такое мета-обучение и MAML?**

Ответ: Мета-обучение — «обучение учиться»: обучающими примерами служат целые задачи. MAML ищет такую инициализацию весов, из которой модель быстро (за несколько шагов градиента) адаптируется к новой задаче.

6. **Что такое zero-shot обучение?**

Ответ: Классификация по классам, для которых не было размеченных обучающих примеров, например по их текстовым описаниям.

7. **Опишите идею CLIP.**

Ответ: Image- и text-энкодеры обучаются контрастно на парах (картинка, подпись): эмбединги пар сближаются, остальных — отдаляются. Zero-shot классификация — выбор класса, текстовый эмбединг которого ближе всего к эмбедингу картинки.

7. RNN, LSTM, GRU

1. **Что такое RNN?**

Ответ: Рекуррентная нейронная сеть, обрабатывающая последовательные данные с сохранением состояния (в так называемом скрытом состоянии).

2. **Что такое LSTM?**

Ответ: RNN с ячейками памяти и гейтами (forget, input, output) для контроля потока информации; аддитивное обновление ячейки ослабляет затухание градиентов.

3. **Что такое GRU?**

Ответ: Упрощённая версия LSTM с двумя гейтами (обновления и сброса) и без отдельной ячейки памяти.

4. **Запишите формулу обновления скрытого состояния в стандартном RNN.**

Ответ: $h_t = \tanh(x_t W_{ih}^T + b_{ih} + h_{t-1} W_{hh}^T + b_{hh})$.

8. Генеративные модели

1. **Что называют латентным пространством?**

Ответ: Это пространство скрытых представлений данных, где компактно хранятся их ключевые особенности.

2. **Что такое автоэнкодер и какова его структура?**

Ответ: Сеть, которая сжимает данные в латентное пространство и восстанавливает обратно. Состоит из энкодера и декодера, обучается минимизировать ошибку реконструкции.

3. **Как работает декодер в автоэнкодере?**

Ответ: Берёт латентный вектор и преобразует его обратно в объект (например, изображение).

4. **Чем VAE отличается от обычного автоэнкодера?**

Ответ: Энкодер VAE выдаёт параметры распределения $q_\phi(z|x)$ (обычно μ, σ), а не точку; $z = \mu + \sigma \odot \epsilon$, $\epsilon \sim \mathcal{N}(0, I)$ (reparameterization trick).

5. **Что такое генеративно-состязательная сеть (GAN)?**

Ответ: Модель, где генератор создаёт объекты из шума, а дискриминатор пытается отличить их от настоящих.

6. **Объясните термин mode collapse. Для какого семейства генеративных моделей свойственен mode collapse?**

Ответ: Генератор начинает выдавать очень ограниченное разнообразие результатов. Характерно для GAN.

7. Почему GAN часто нестабилен при обучении?

Ответ: Из-за состязательного процесса и чувствительности к балансу между сетями.

8. Что такое диффузионная модель?

Ответ: Модель, которая учится пошагово удалять шум, восстанавливая объект из чистого шума.

9. Как организован процесс добавления шума при обучении диффузионной модели?

Ответ: Гауссовский шум добавляется постепенно по расписанию (schedule), за T шагов приближая объект к чистому шуму.

10. Что обычно предсказывает нейросеть в диффузионной модели?

Ответ: Шум ε , добавленный на шаге t : минимизируется $\|\varepsilon - \varepsilon_\theta(x_t, t)\|^2$. Также встречается предсказание x_0 или v .

11. В чём недостаток диффузионных моделей с точки зрения вычислительных затрат?

Ответ: Им нужно много шагов, что делает генерацию медленной.

12. Что такое нормализационные потоки?

Ответ: Обратимые преобразования простого распределения в сложное; правдоподобие считается точно по формуле замены переменных: $\log p_x(x) = \log p_z(f^{-1}(x)) + \log \left| \det \frac{\partial f^{-1}}{\partial x} \right|$.

13. Каковы основные ограничения нормализационных потоков?

Ответ: Преобразования должны быть обратимы и иметь легко вычисляемый якобиан, что сильно ограничивает архитектуру.

9. Трансформеры и LLM

1. Что такое механизм внимания?

Ответ: Attention — это способ выделить самые важные части входа для текущего шага обработки.

2. Что означают термины Query, Key, Value?

Ответ: Это три представления токенов, через которые считается внимание.

- Query (запрос) — что я ищу?
- Key (ключ) — что я предлагаю?
- Value (значение) — что я получу, если сопоставление подошло?

3. Как вычисляется attention?

Ответ:

$$\text{Attention}(Q, K, V) = \text{softmax} \left(\frac{QK^T}{\sqrt{d_k}} \right) V.$$

4. Зачем нужны несколько голов внимания?

Ответ: Разные головы используют разные проекции Q , K , V и могут улавливать разные закономерности в данных.

5. Что делает position encoding и зачем он нужен?

Ответ: Он добавляет информацию о позиции токенов, которой self-attention сам по себе не учитывает.

6. **Что делает masked self-attention?**

Ответ: Запрещает смотреть на будущие токены при генерации (логиты для них заменяются на $-\infty$ перед softmax).

7. **Чем GPT отличается от BERT?**

Ответ: GPT — Decoder, BERT — Encoder.

8. **Что такое greedy search и beam search?**

Ответ: Greedy на каждом шаге берёт самый вероятный токен. Beam search хранит k наиболее вероятных частичных последовательностей и продолжает каждую из них.

9. **Что такое temperature, top-k и top-p sampling?**

Ответ: Temperature: логиты делятся на T перед softmax ($T < 1$ — выбор увереннее, $T > 1$ — разнообразнее). Top-k: сэмплирование из k самых вероятных токенов. Top-p: из минимального набора самых вероятных токенов с суммарной вероятностью $\geq p$.

10. **Что такое LoRA?**

Ответ: LoRA (Low-Rank Adaptation) — это метод дообучения больших нейросетей, при котором основные веса модели замораживаются, а обучение идёт только по небольшим низкоранговым добавкам: $W = W_0 + BA$, $B \in \mathbb{R}^{d \times r}$, $A \in \mathbb{R}^{r \times k}$, $r \ll \min(d, k)$.

10. Воспроизводимость экспериментов

1. **Зачем нужна отдельная тестовая выборка, если есть валидационная?**

Ответ: По валидации подбираются гиперпараметры и выбирается модель, поэтому оценка на ней оптимистична; test используется один раз для честной итоговой оценки.

2. **Как зафиксировать случайность эксперимента в PyTorch?**

Ответ: Зафиксировать seed для random, numpy и torch (включая torch.cuda) и для перемешивания в DataLoader.

3. **Гарантирует ли фиксированный seed одинаковый результат на GPU?**

Ответ: Не всегда: некоторые CUDA-операции недетерминированы (порядок суммирования), поэтому результаты могут немного отличаться.