Contrastive + Pose estimation

Идентификация или почему не классификация

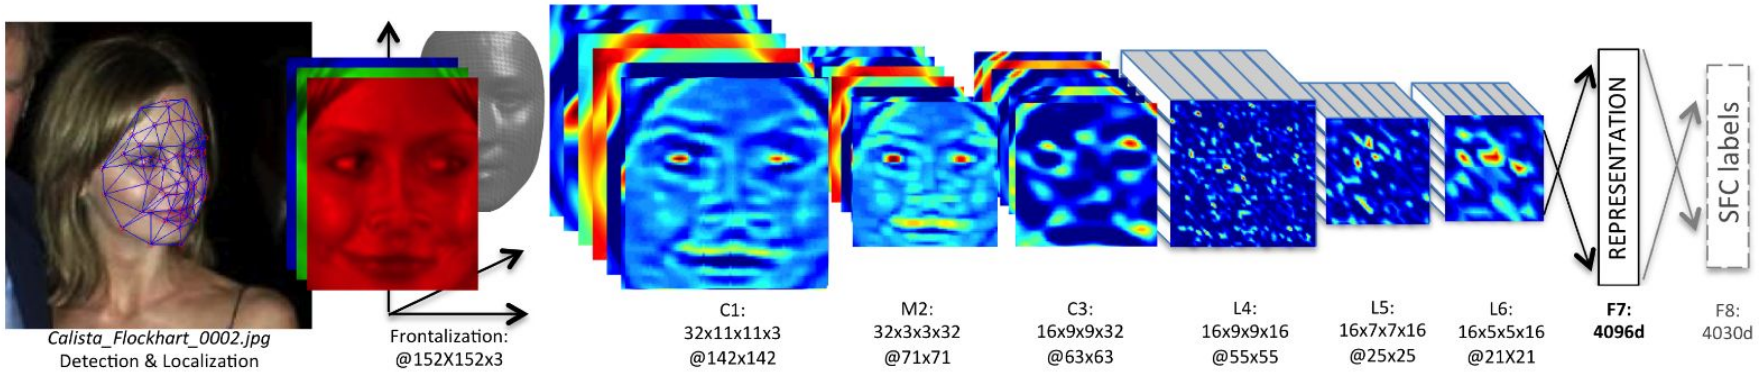
Labeled Faces in the Wild

Около 13 000 фоток на около 6000 людей



http://vis-www.cs.umass.edu/lfw/#information

Классическое CV рулит! (DeepFace)



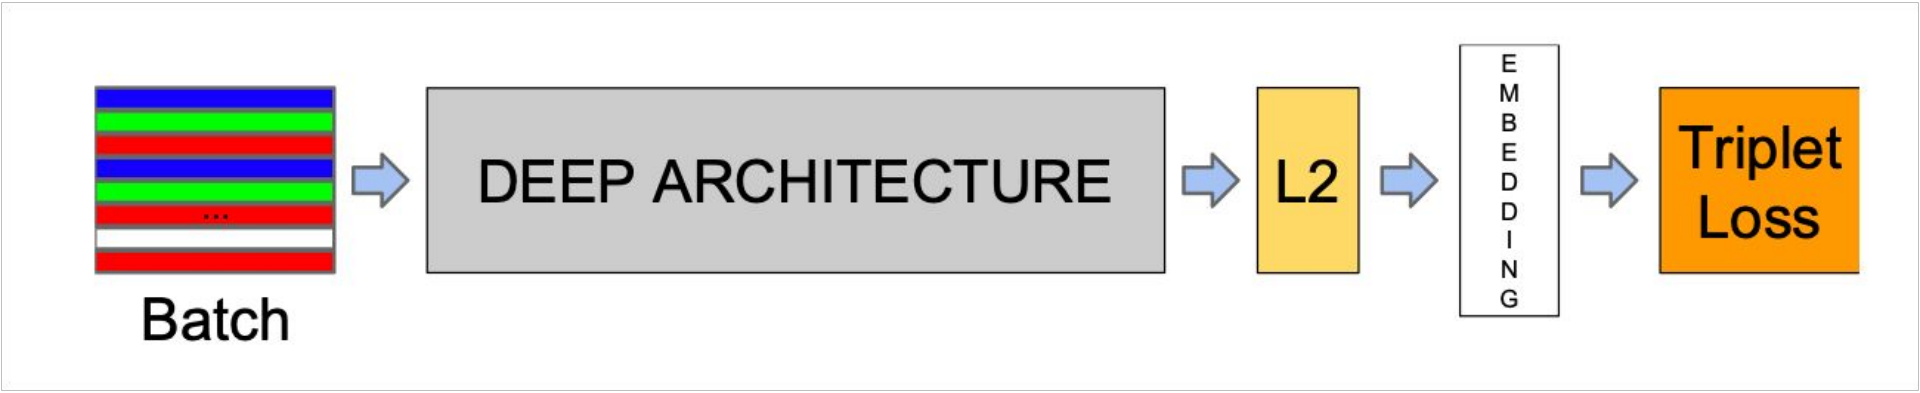
https://www.cs.toronto.edu/~ranzato/publications/taigman_cvpr14.pdf

DeepFace

Обучаем некоторую архитектуру для классификации (число классов = число людей в данных)
Используем выходы предпоследнего слоя как признаковое описание изображения
Признаки нормализуются (чтобы норма была единичной)
Считаем близость векторов по какой-нибудь метрике

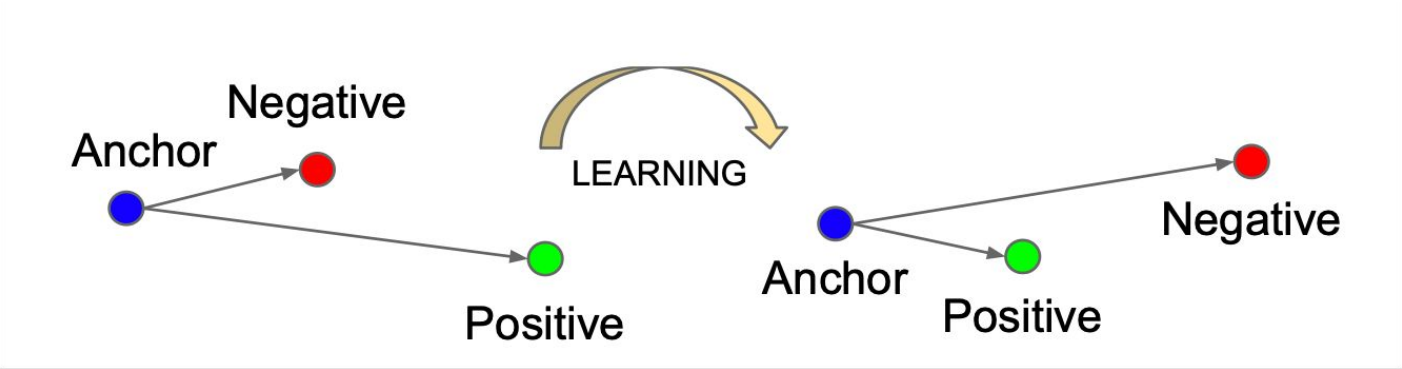
FaceNet

А давайте похожие люди сразу рядом будут?



https://arxiv.org/pdf/1503.03832.pdf

TripletLoss



$$\sum_{i}^{N} \left[\|f(x_i^a) - f(x_i^p)\|_2^2 - \|f(x_i^a) - f(x_i^n)\|_2^2 + \alpha \right]_+$$

InfoNCE

$$L_{\text{InfoNCE}} = -\log \frac{\exp(\text{sim}(a, p)/\tau)}{\exp(\text{sim}(a, p)/\tau) + \sum_i \exp(\text{sim}(a, n_i)/\tau)}$$

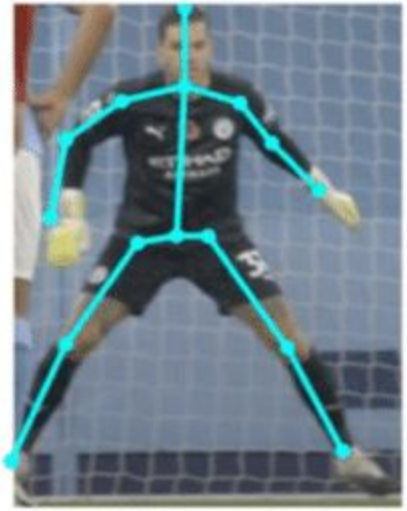
Зачем оно надо?

1) В триплете негативный пример – один объект, тут целый батч
2) В каком-то смысле это – многоклассовая задача. Надо найти позитивную “иголку” в стоге отрицательного “сена”
3) Иногда у TripletLoss приходится заняться Hard Negative Mining, здесь эта необходимость гораздо ниже

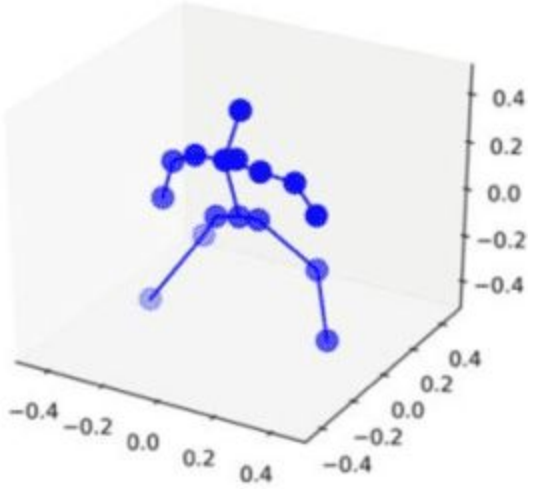
Pose estimation



(a) Input Image



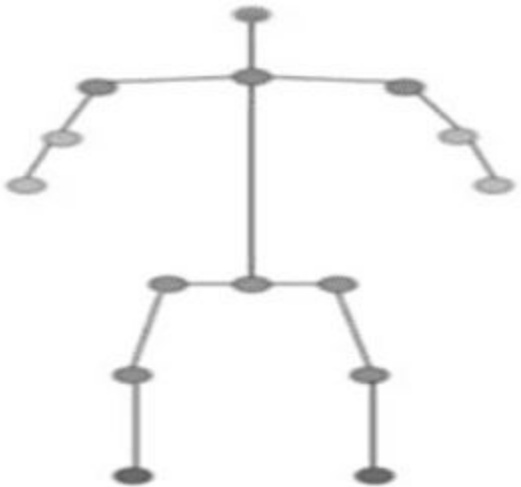
(b) 2D Pose Estimation



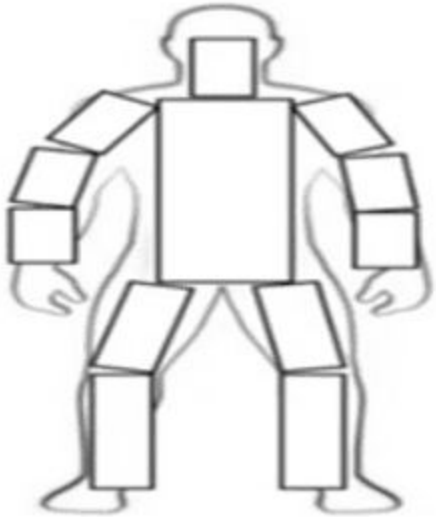
(c) 3D Pose Estimation

https://www.researchgate.net/figure/The-3D-pose-estimation-model-predicts-both-the-2D-and-3D-pose-coordinates_fig3_358846261

(a)



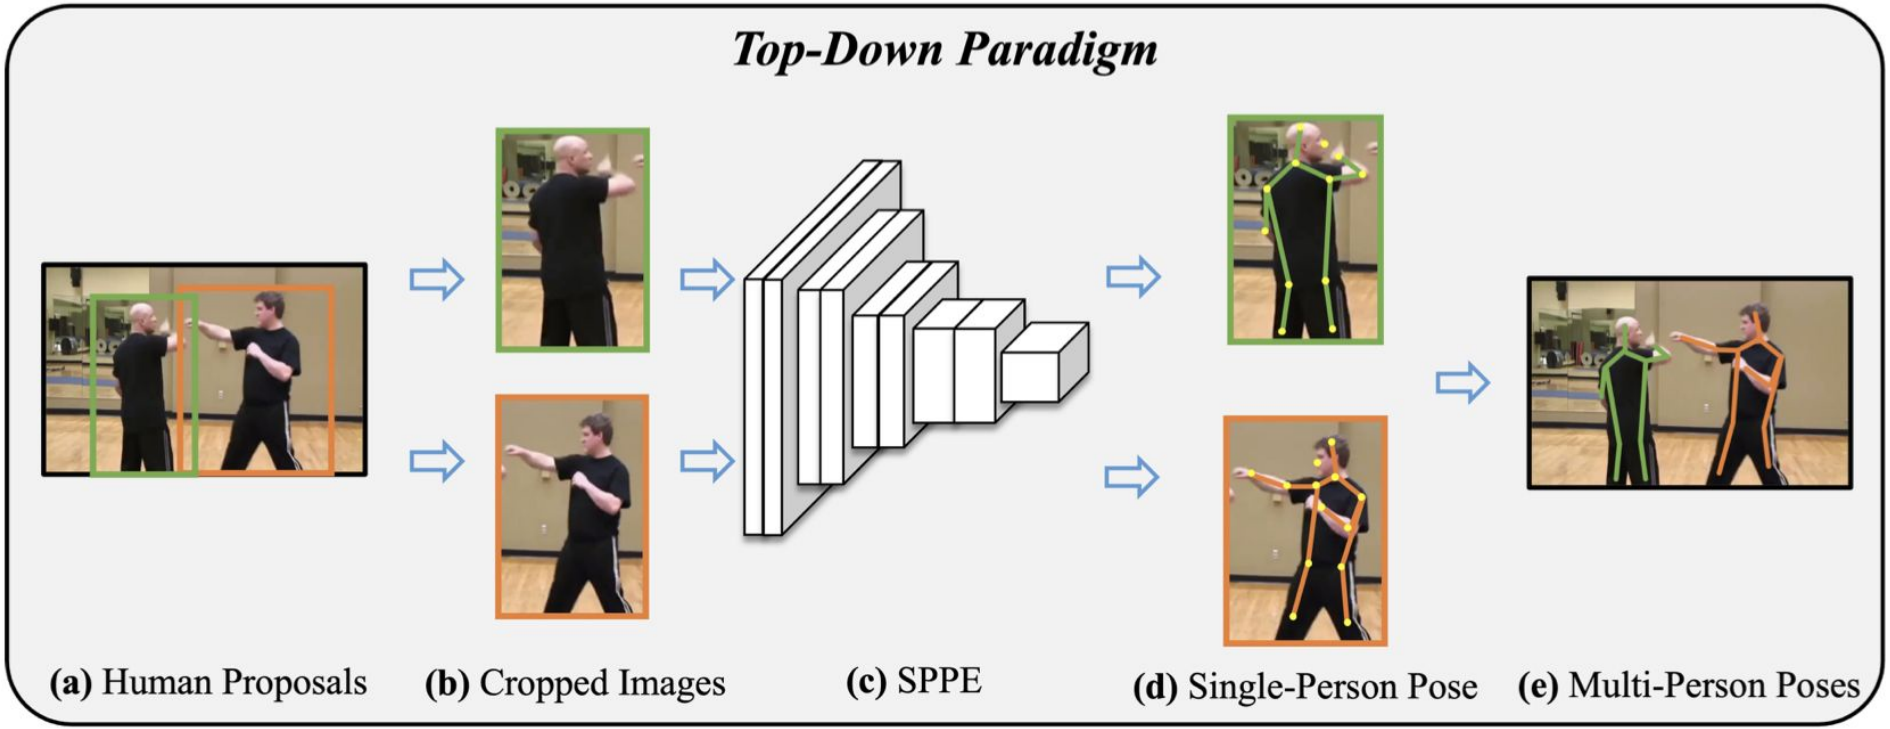
(b)



(c)

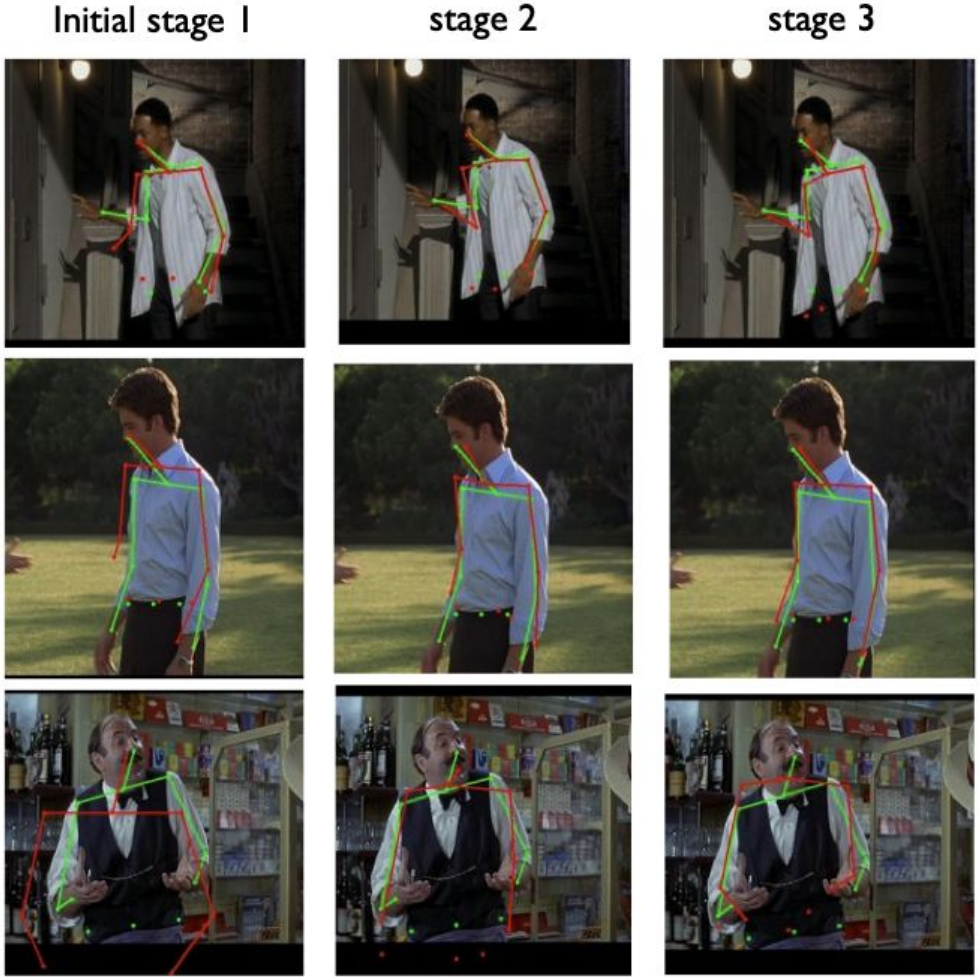


Базовая идея



https://arxiv.org/pdf/2204.07370


Initial stage
220 x 220
55 x 55 x 48
27 x 27 x 128
13 x 13 x 192
13 x 13 x 192
13 x 13 x 192
4096
4096
x_i
y_i
...
DNN-based regressor
(x_i, y_i)
Stage s
$(x^{(s-1)}_i, y^{(s-1)}_i)$
55 x 55 x 48
27 x 27 x 128
13 x 13 x 192
13 x 13 x 192
13 x 13 x 192
4096
4096
$x^s_i - x^{(s-1)}_i$
$y^s_i - y^{(s-1)}_i$
DNN-based refiner
send refined values
to next stage


Initial stage 1
stage 2
stage 3

Минусы

Флешбеки на RCNN? :)

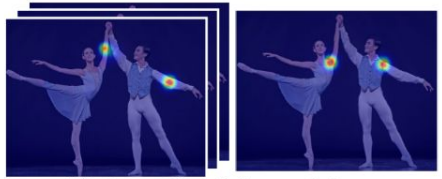
OpenPose или bottom up



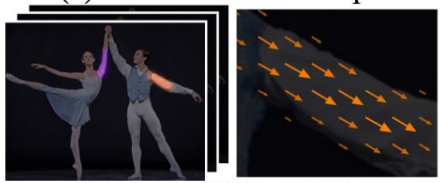
https://arxiv.org/pdf/1611.08050



(a) Input Image



(b) Part Confidence Maps



(c) Part Affinity Fields



(d) Bipartite Matching



(e) Parsing Results

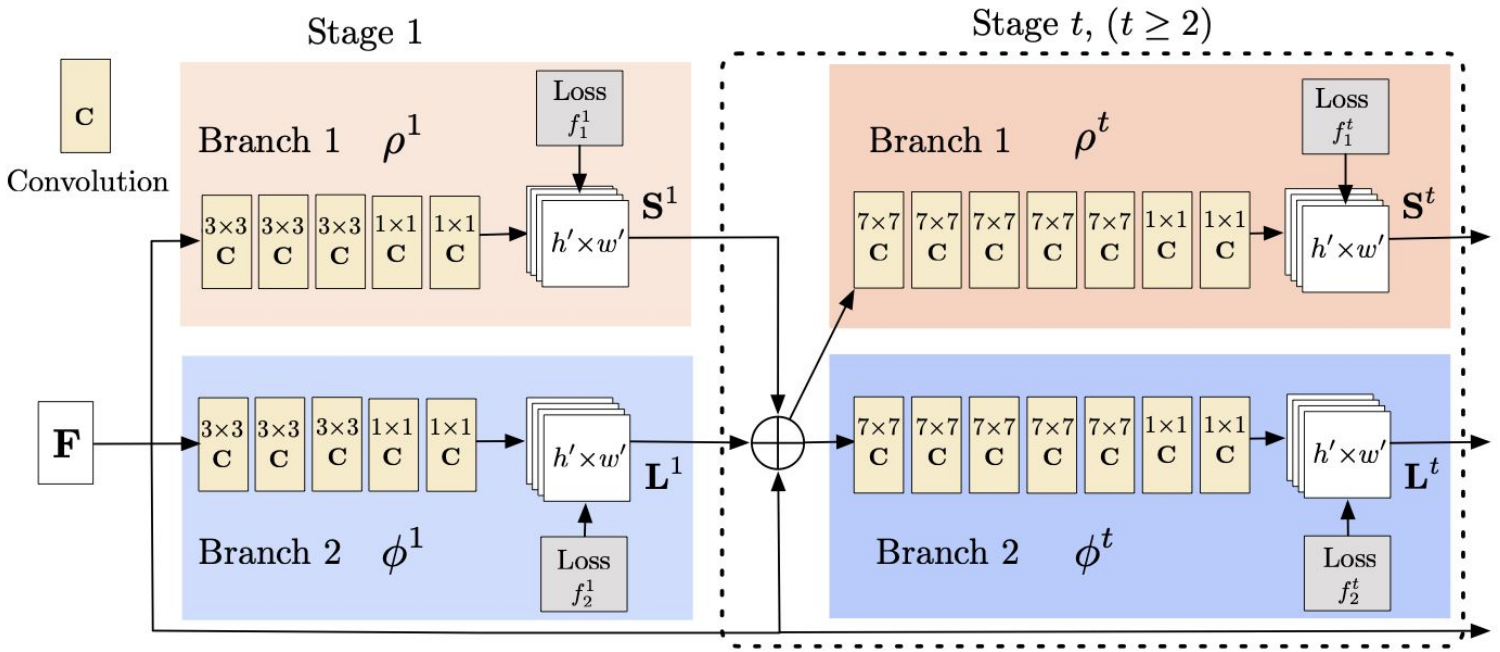
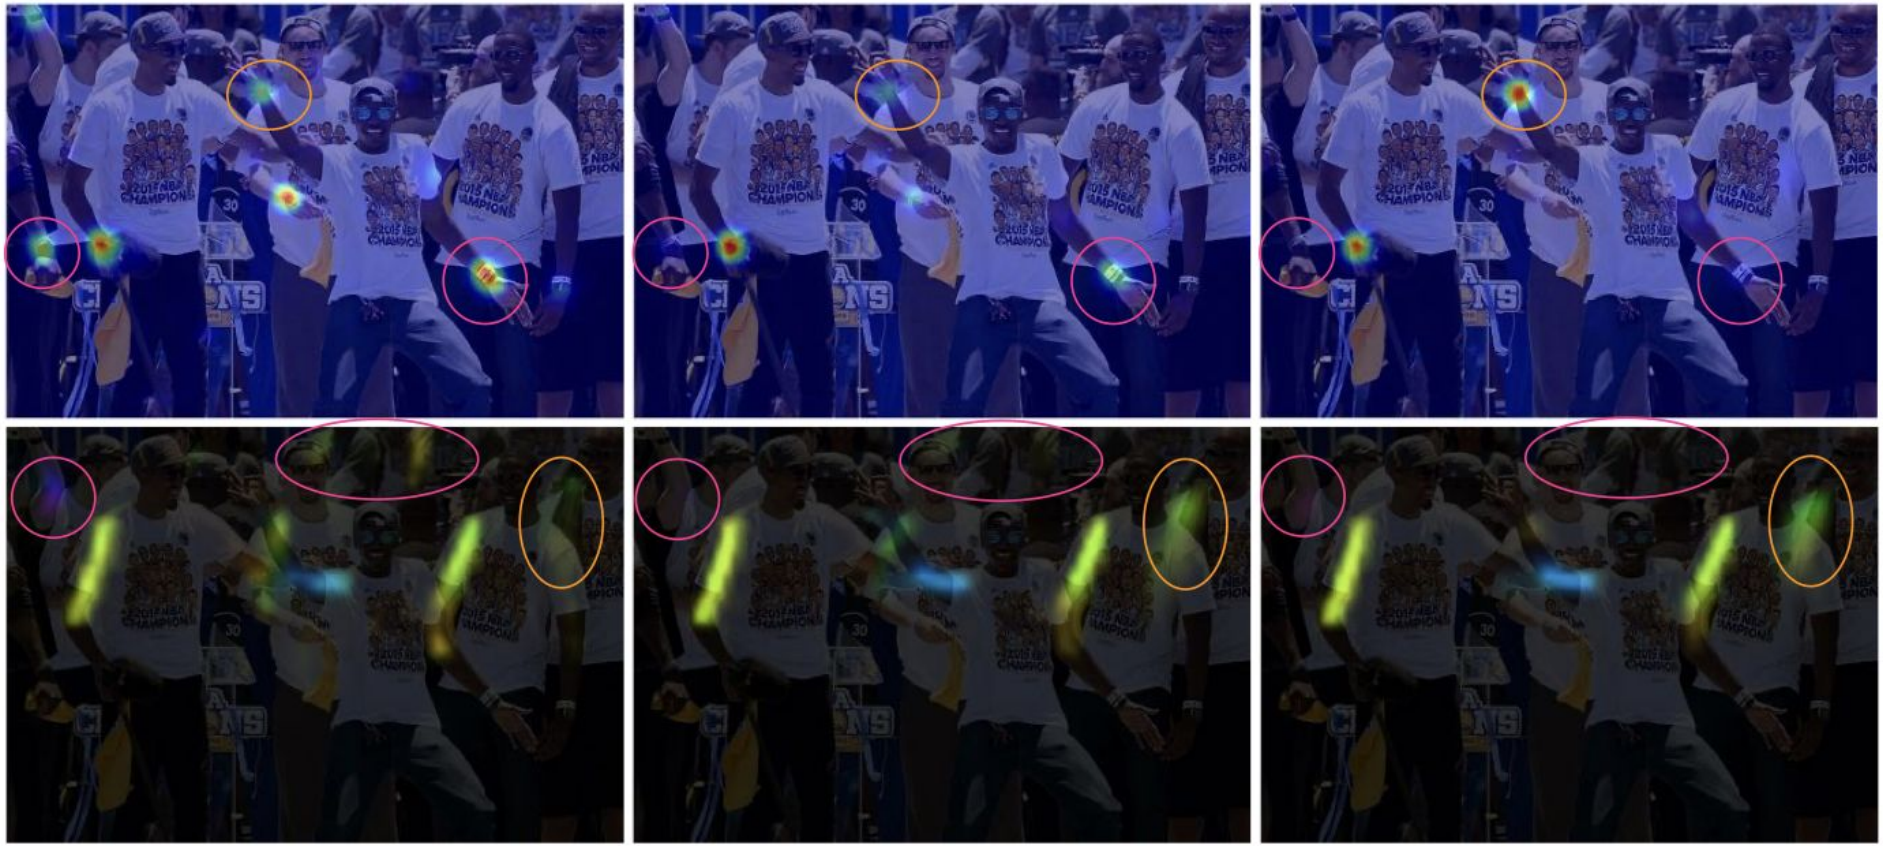
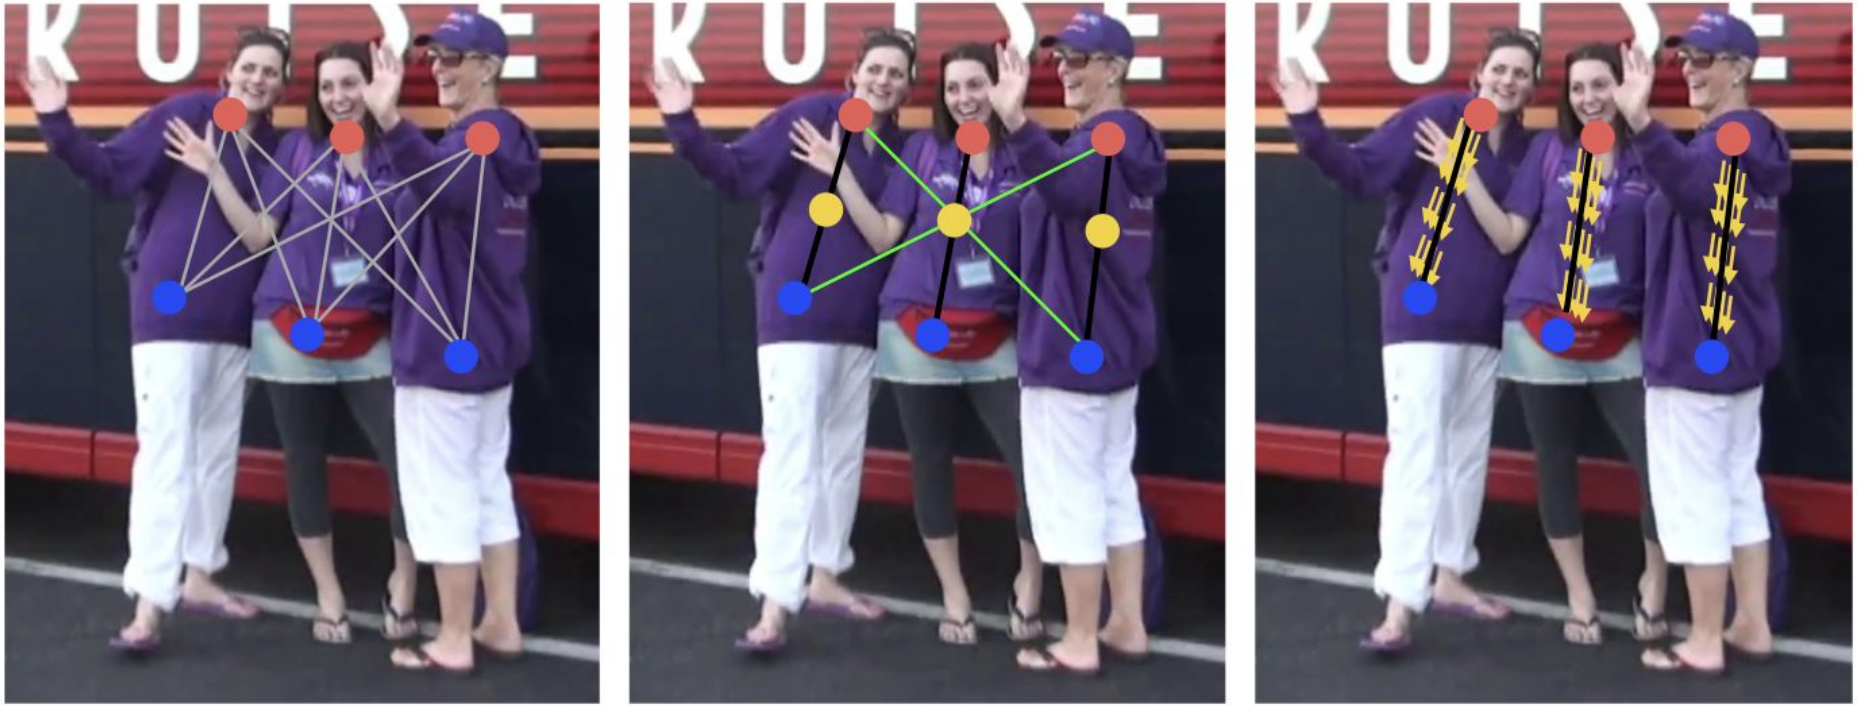


Figure 3. Architecture of the two-branch multi-stage CNN. Each stage in the first branch predicts confidence maps $\mathbf{S}^t$, and each stage in the second branch predicts PAFs $\mathbf{L}^t$. After each stage, the predictions from the two branches, along with the image features, are concatenated for next stage.

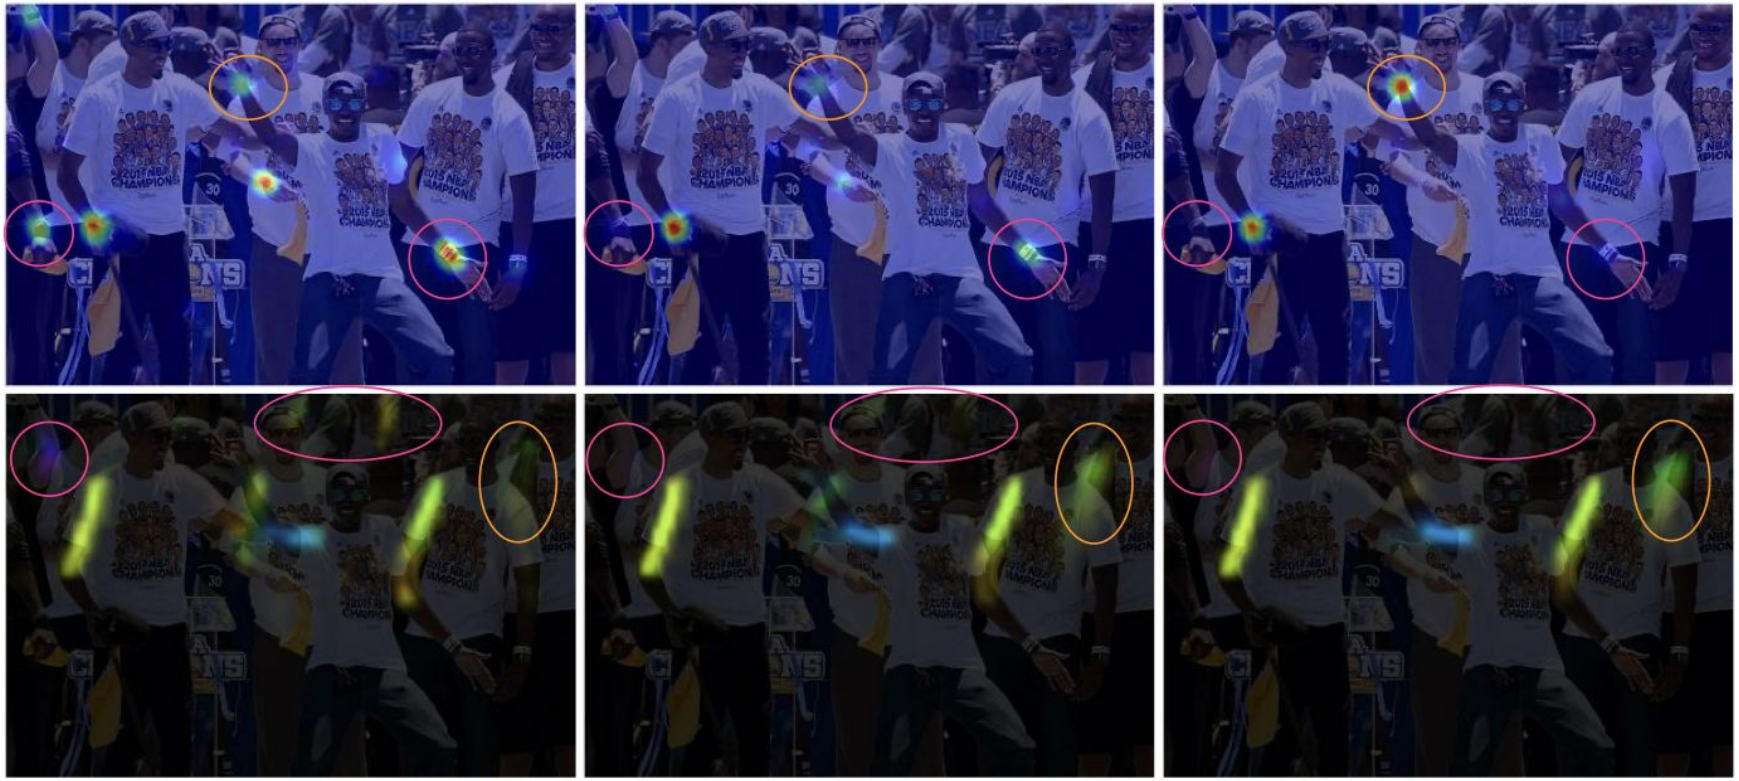


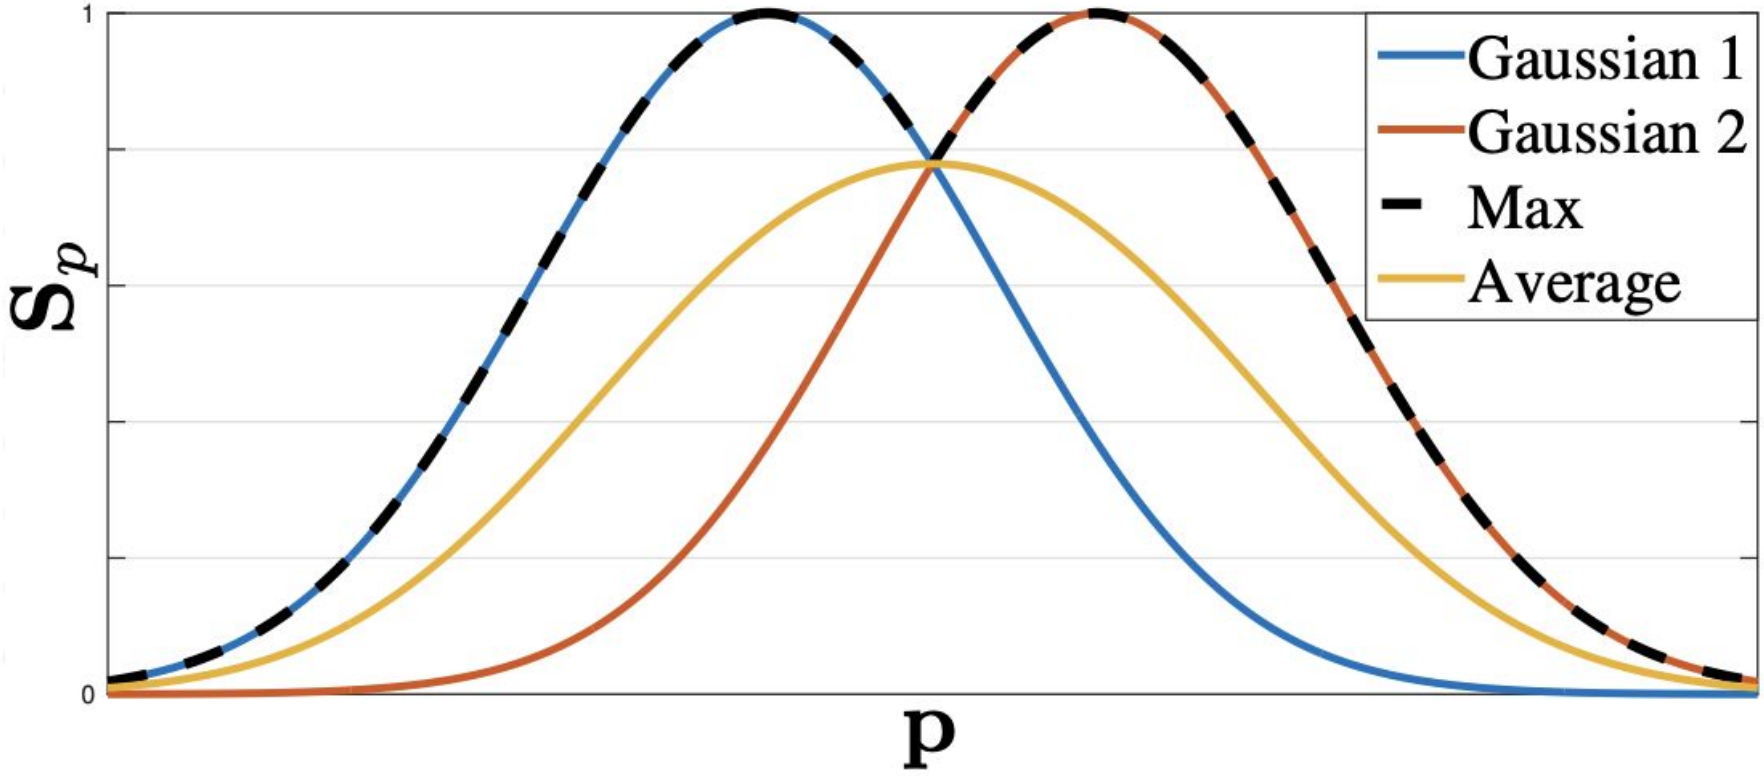
Stage 1 Stage 3 Stage 6



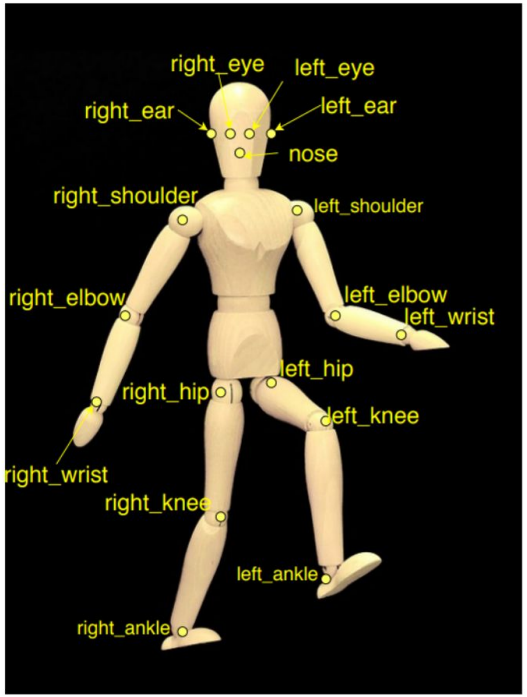
(a) (b) (c)

Как формировать таргет?

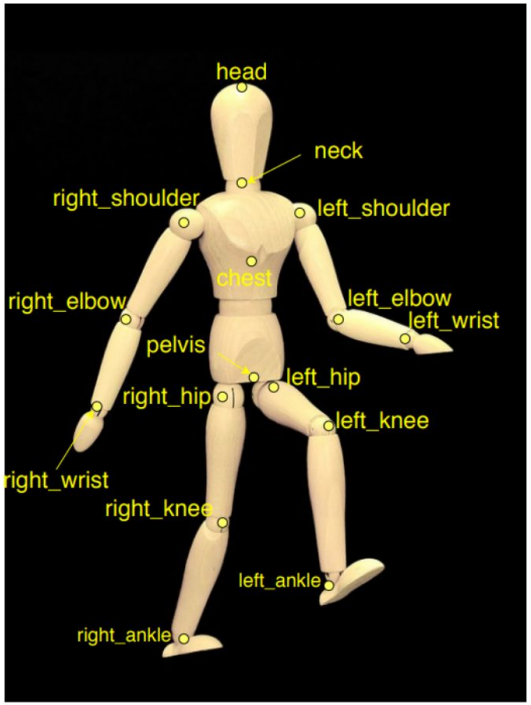



1
0
S_p
p
Gaussian 1
Gaussian 2
Max
Average

Датасеты как бы есть, но как бы :)))



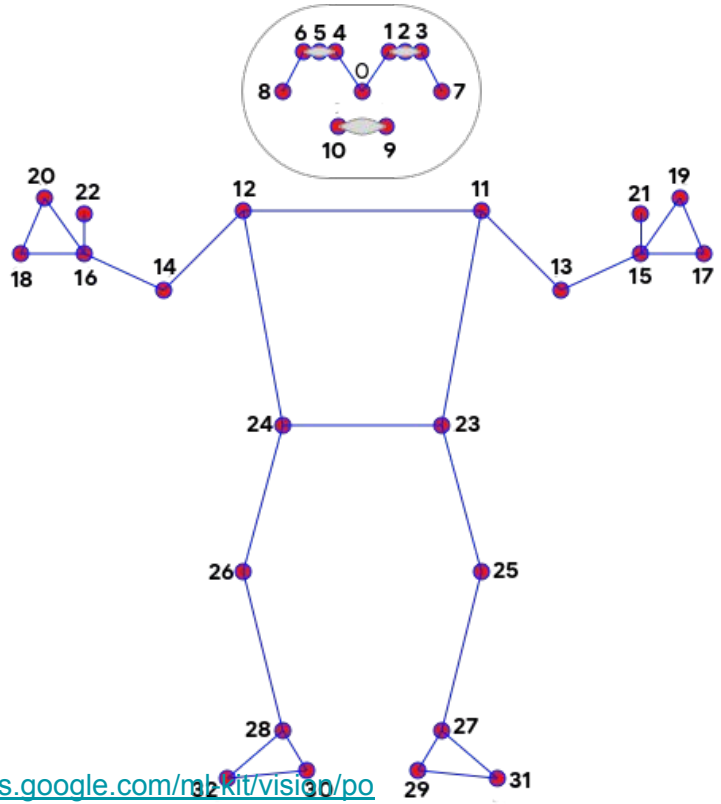
Coco dataset keypoints



MPII dataset keypoints

https://repository.tudelft.nl/record/uuid:cf50ef4b-801b-4645-aab5-31c55abf07a1

Google ML Kit (mediapipe)

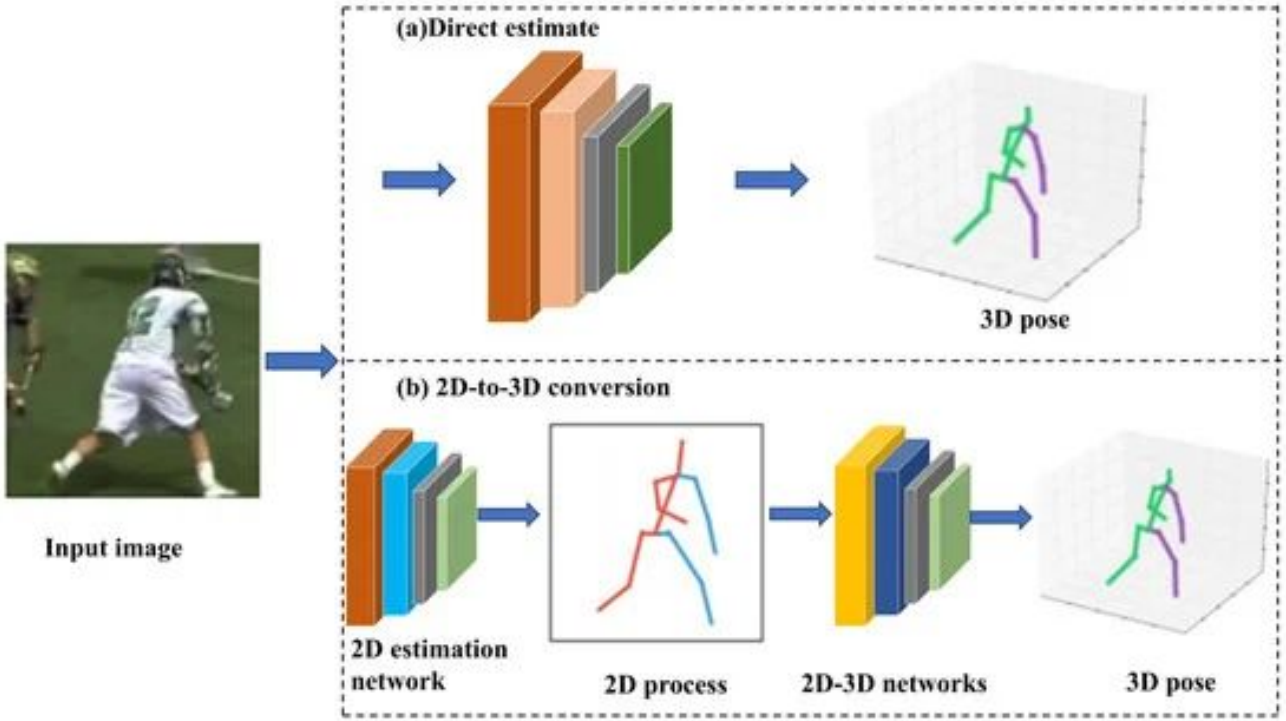


Landmarks

0. Nose
1. Left_eye_inner
2. Left_eye
3. Left_eye_outer
4. Right_eye_inner
5. Right_eye
6. Right_eye_outer
7. Left_ear
8. Right_ear
9. Left_mouth
10. Right_mouth
11. Left_shoulder
12. Right_shoulder
13. Left_elbow
14. Right_elbow
15. Left_wrist
16. Right_wrist
17. Left_pinky
18. Right_pinky
19. Left_index
20. Right_index
21. Left_thumb
22. Right_thumb
23. Left_hip
24. Right_hip
25. Left_knee
26. Right_knee
27. Left_ankle
28. Right_ankle
29. Left_heel
30. Right_heel
31. Left_foot_index
32. Right_foot_index

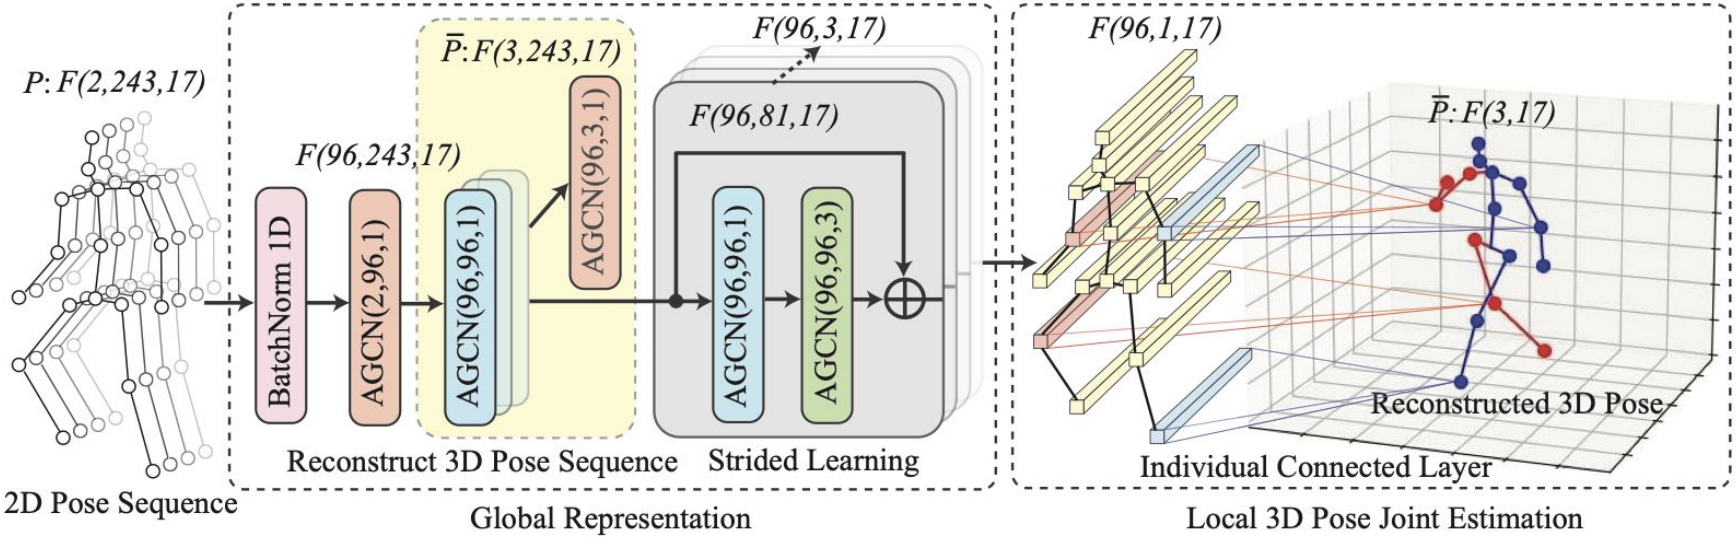
https://developers.google.com/ml-kit/vision/pose-detection?hl=ru

3D Pose estimation или два стула



https://www.mdpi.com/2079-9292/14/7/1307

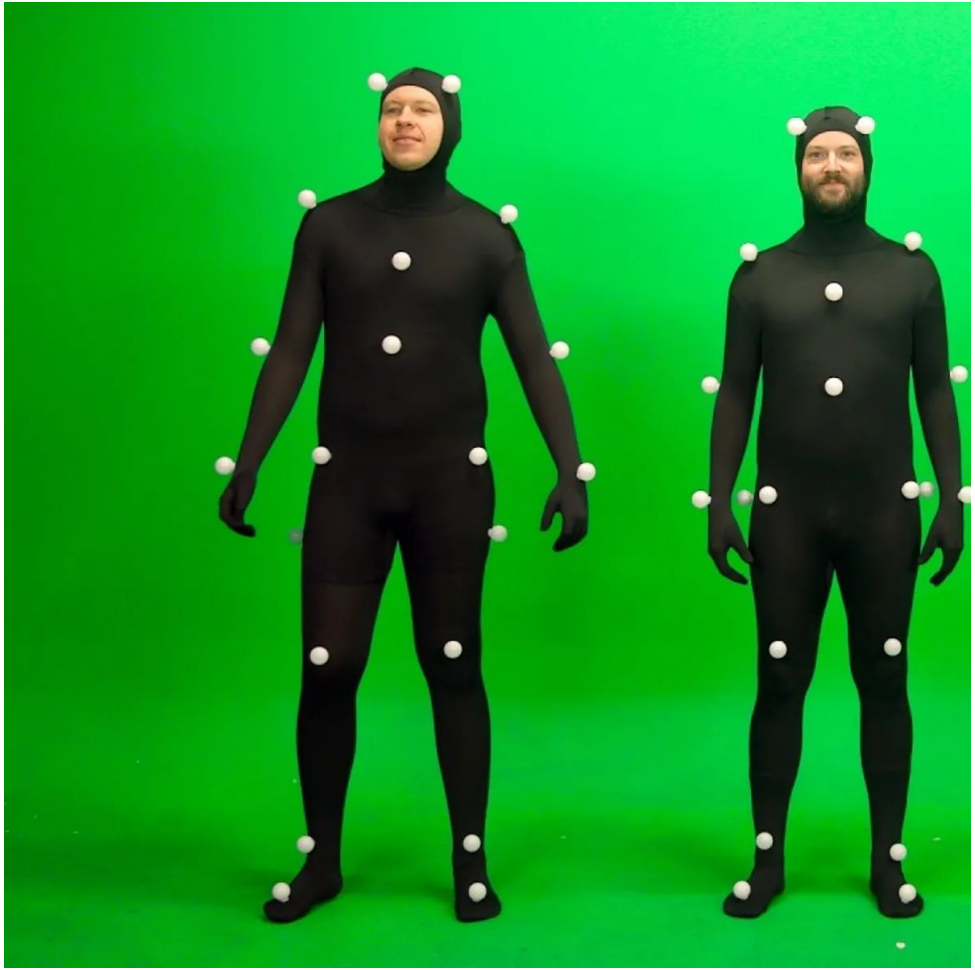
Что можно сделать даже без картинки, только по скелету? GCN + pose estimation



https://openaccess.thecvf.com/content/ICCV2023/papers/Yu_GLA-GCN_Global-local_Adaptive_Graph_Convolutional_Network_for_3D_Human_Pose_ICCV_2023_paper.pdf

Проблемы 3D pose estimation

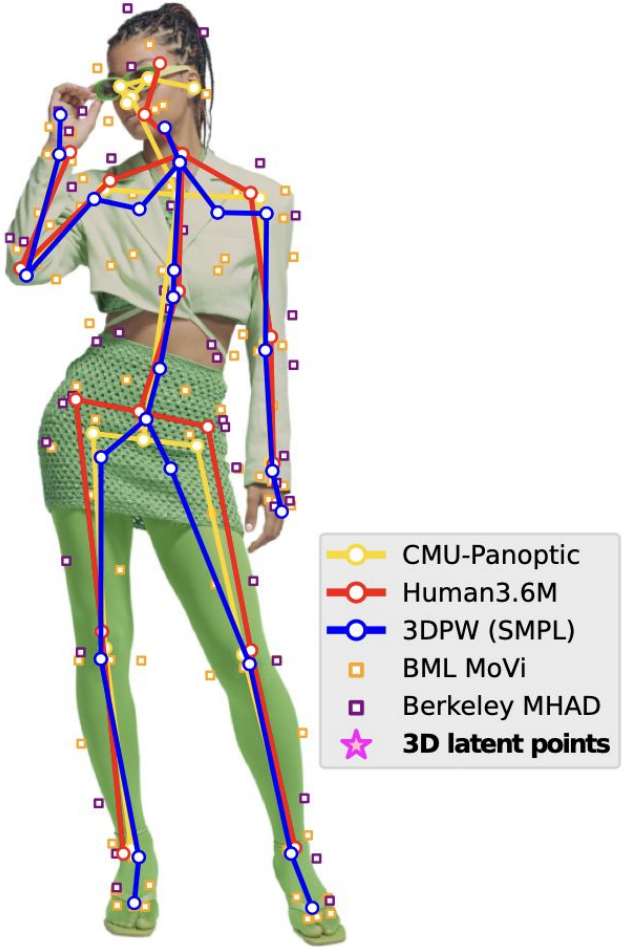
Знакомьтесь, MoCap (motion capture) suit



https://nofilmschool.com/how-to-act-in-mocap-suits

https://arxiv.org/pdf/2212.14474

Разные студии – разные метки



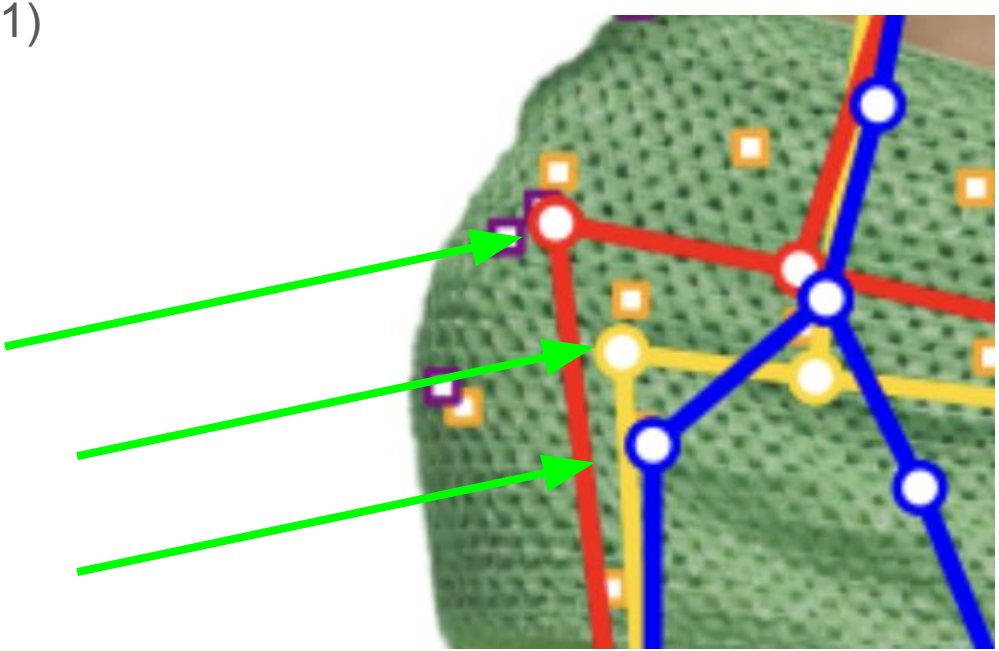
Как быть?

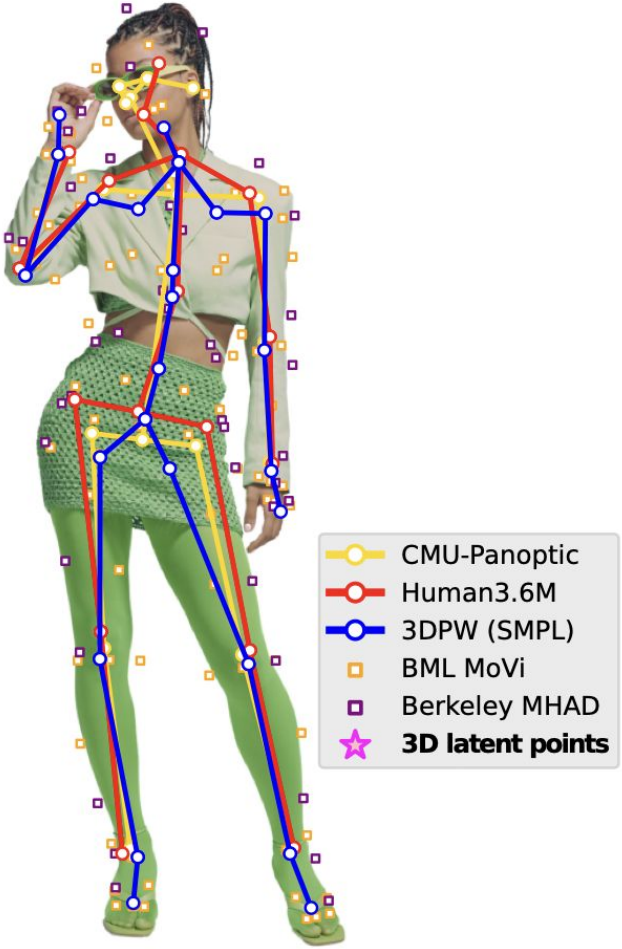
1) Забить и обучать как есть
2) Обучить большую модель, которая будет иметь кучу голов. Надеемся, что оно дружно как-то там внутри обучится и будет все хорошо

https://arxiv.org/pdf/2212.14474

Проблемы

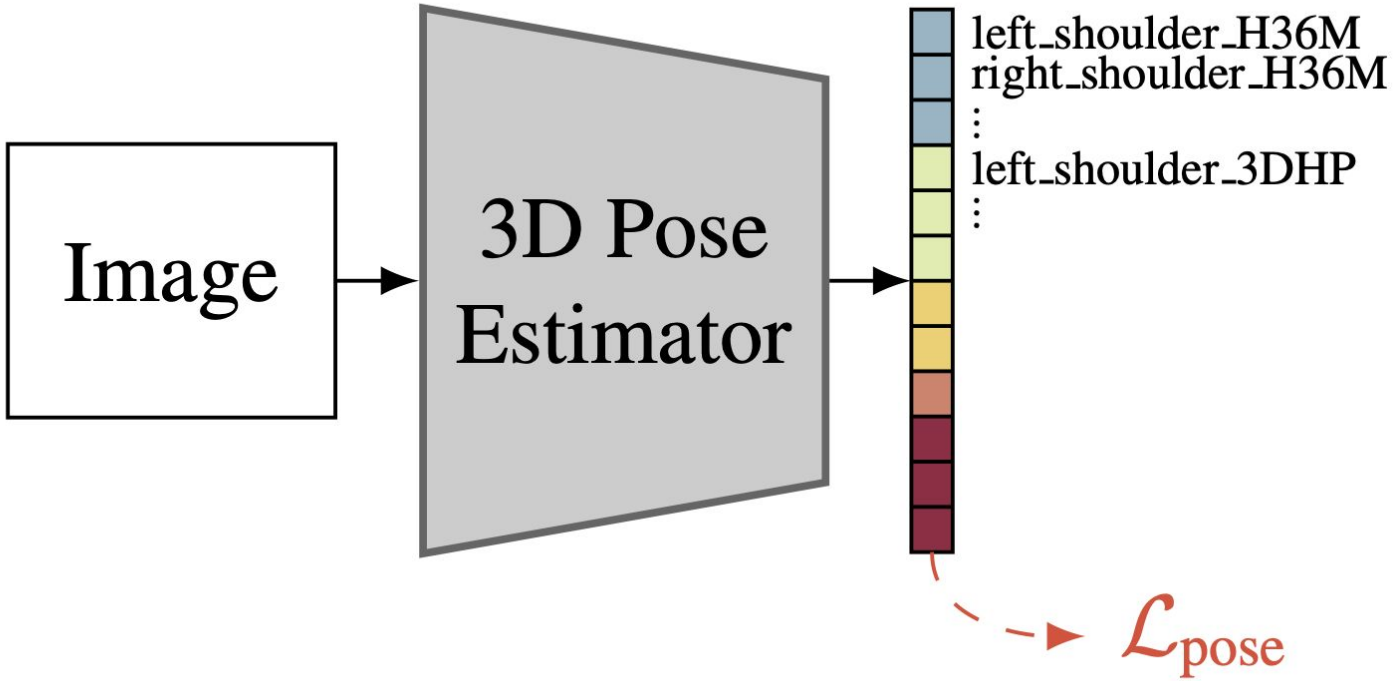
1)





https://arxiv.org/pdf/2212.14474

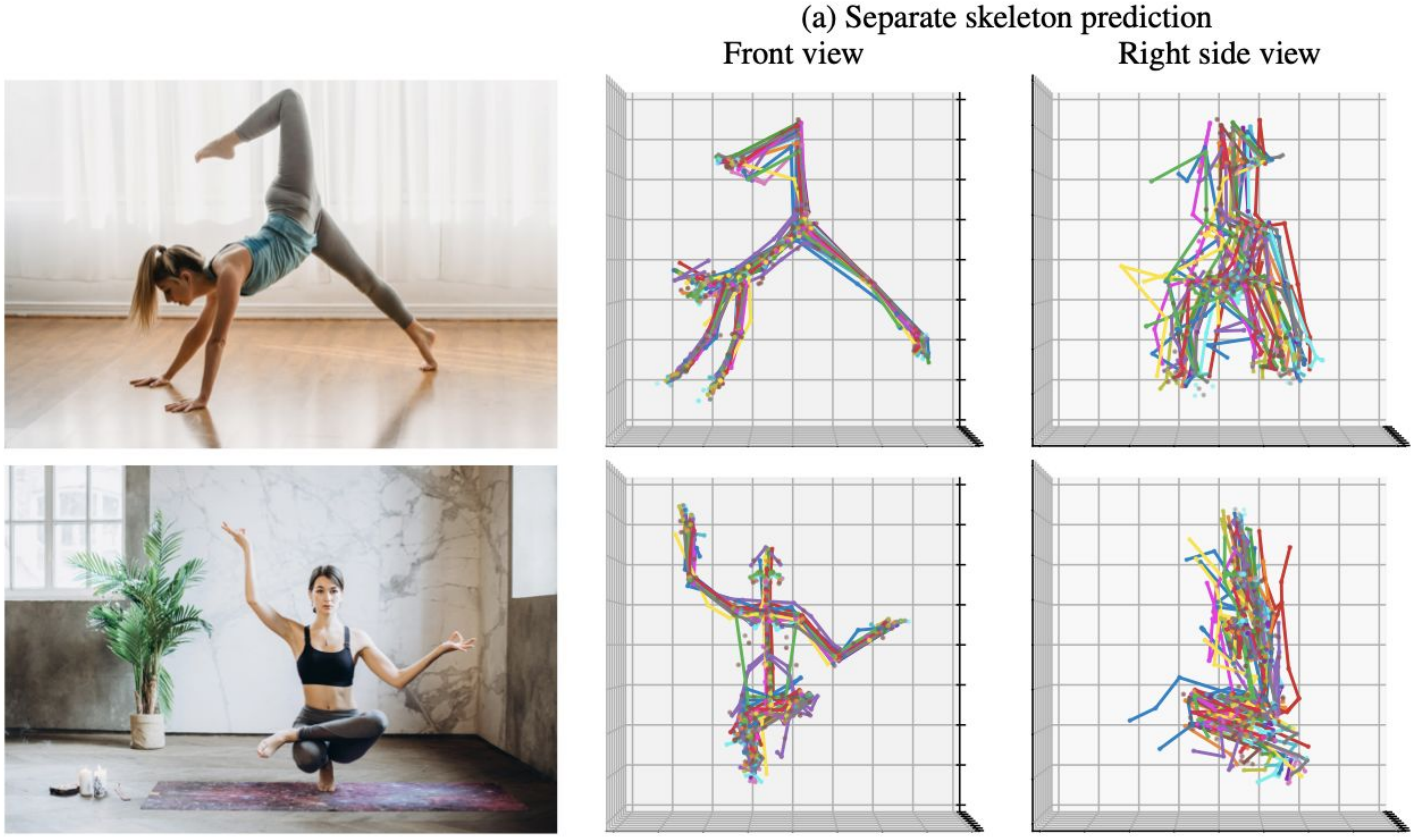
2)



https://arxiv.org/pdf/2212.14474

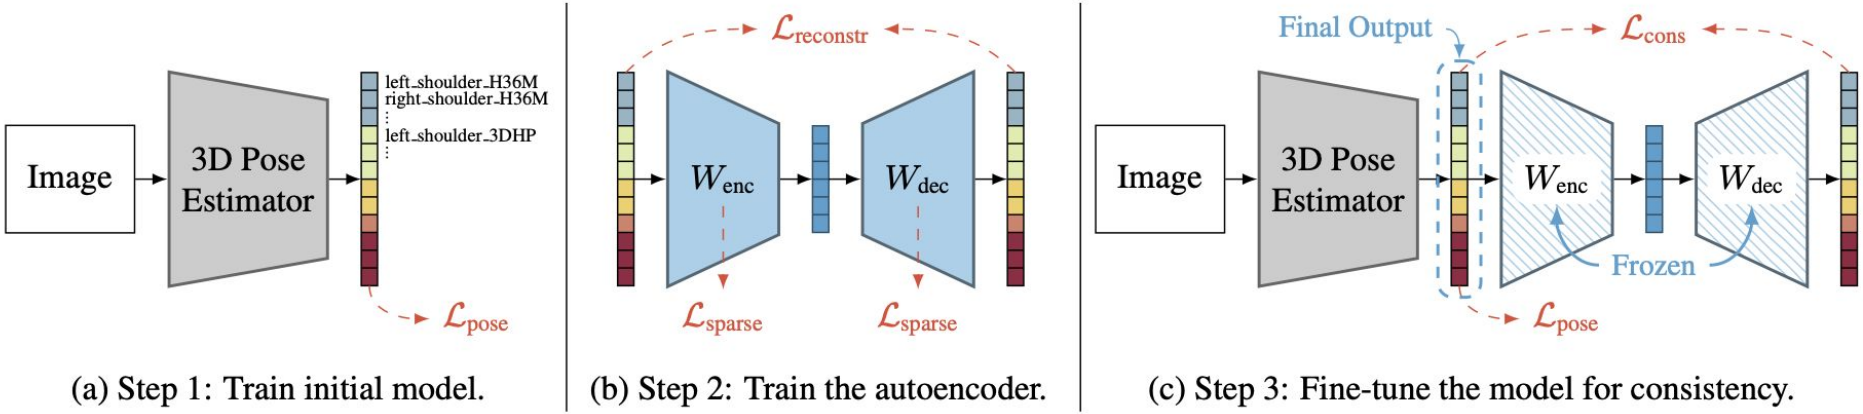
Проблемы

2)



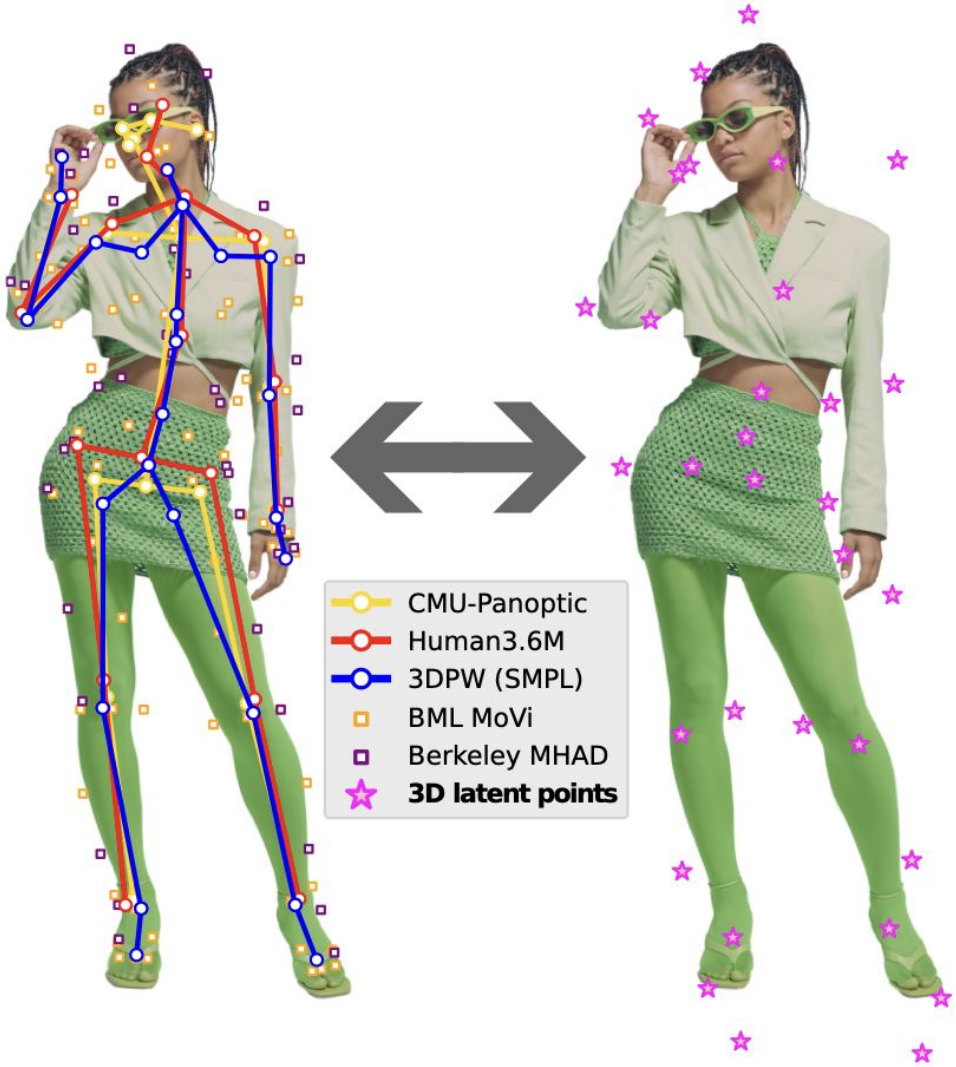
https://arxiv.org/pdf/2212.14474

И как быть?

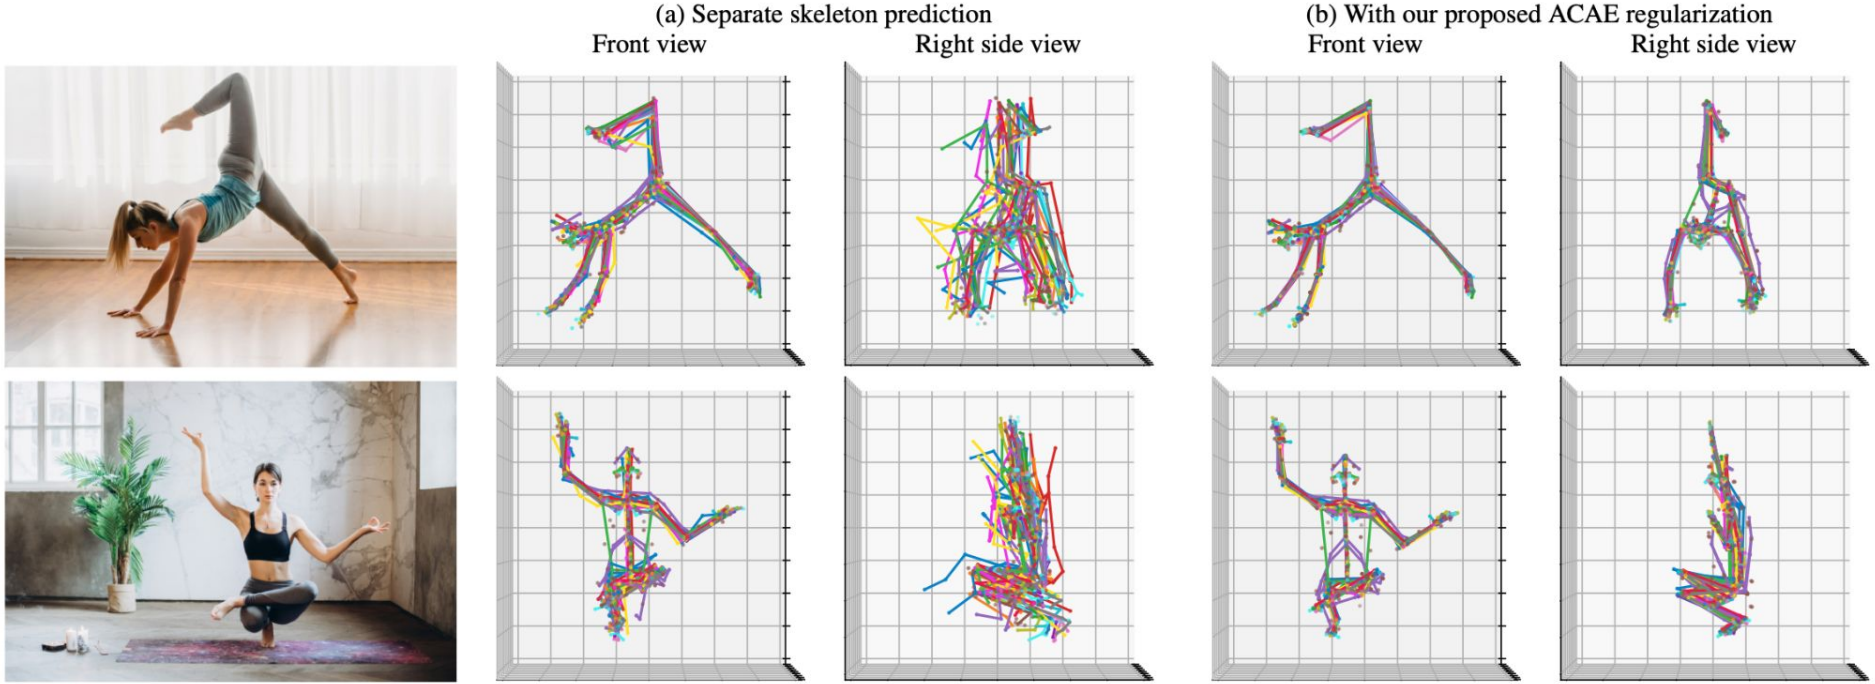


(a) Step 1: Train initial model. (b) Step 2: Train the autoencoder. (c) Step 3: Fine-tune the model for consistency.

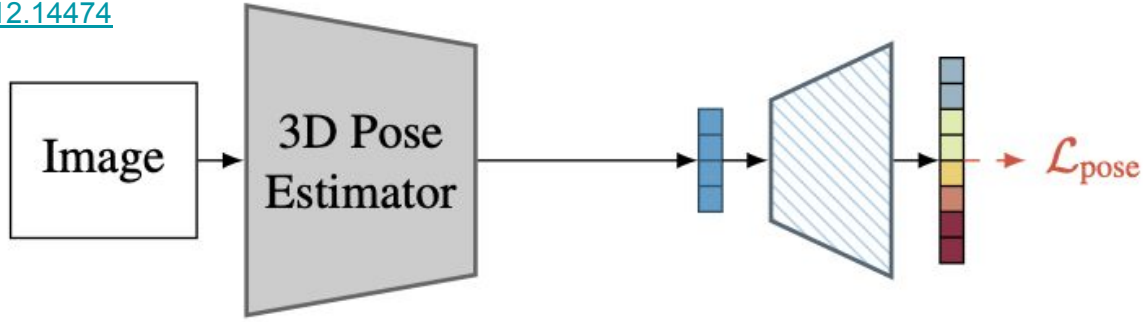
https://arxiv.org/pdf/2212.14474



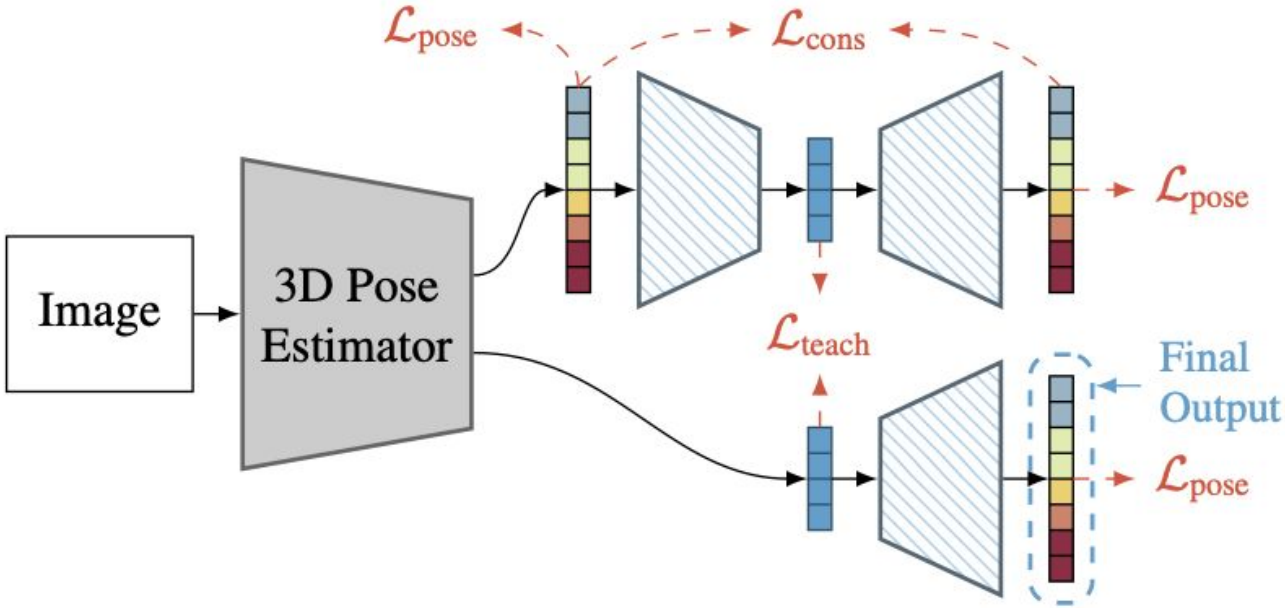
https://arxiv.org/pdf/2212.14474



https://arxiv.org/pdf/2212.14474

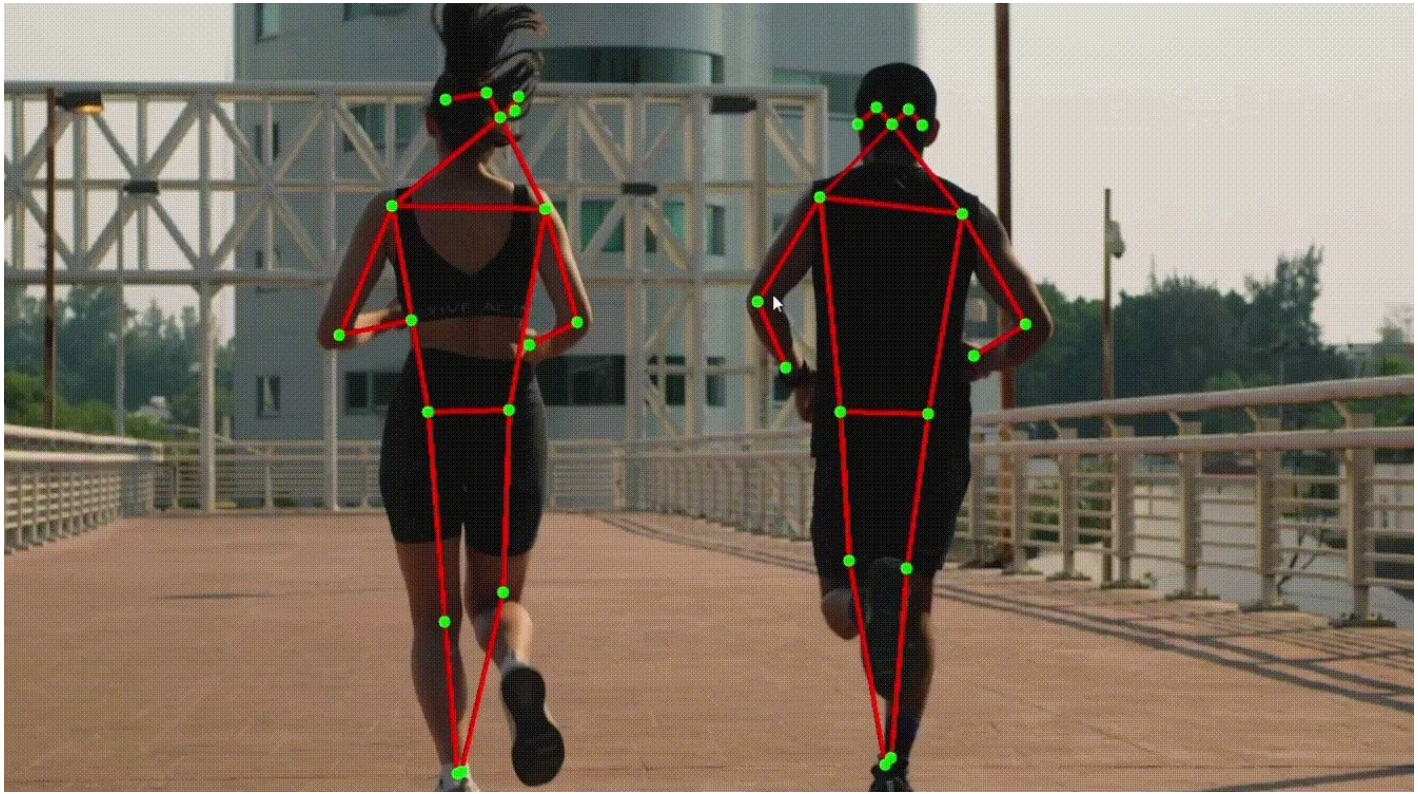


(a) Direct prediction of latent keypoints.



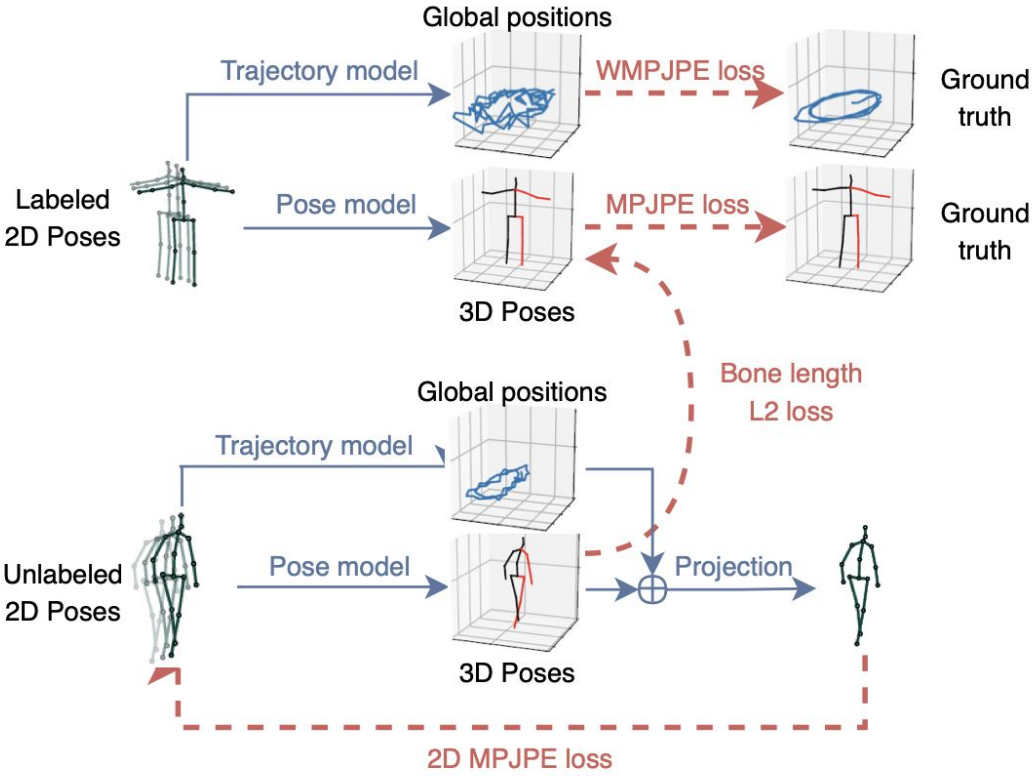
https://github.com/Gnopal1132/Multi-Pose-Estimation?tab=readme-ov-file

Video Pose Estimation или дрыгающиеся скелетики



https://arxiv.org/pdf/1811.11742

Пример решения этой проблемы



Метрики

Percentage of Correct Keypoints

Object Keypoint Similarity

$$OKS = \frac{\sum_{i \in [0,N-1]} exp(\frac{-d_i^2}{2s^2\kappa_i^2})\delta(v_i > 0)}{\sum_{i \in [0,N-1]} \delta(v_i > 0)}$$

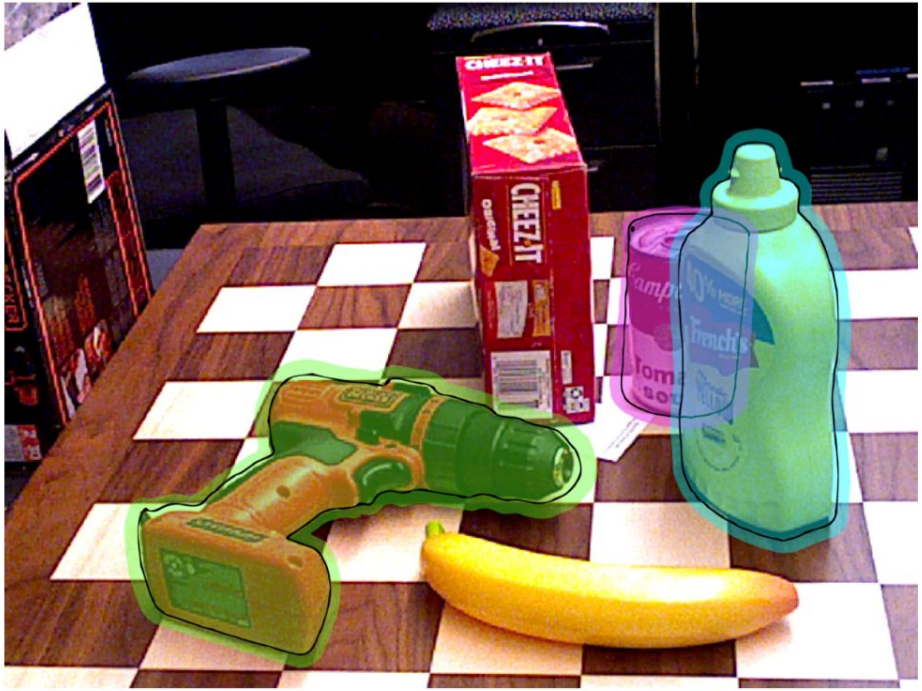
- $s : Object\ scale$
- $d_i : Distance\ of\ predicted\ joint\ i\ from\ ground\ truth$
- $\kappa_i : Per\ keypoint\ constant\ that\ controls\ falloff$
- $v_i : Visibility\ flag.$

https://arxiv.org/pdf/2511.21666v1

Почему хорошая модель в Pose estimation должна быть неуверенной?



(a) LM-O uncertainty



(b) YCB-V uncertainty

Про статью

1) Объединяйтесь в команды по 2-3 человека. В исключительных случаях допускается соло.
2) Находите статью последних ~5 лет, которую можете повторить, не утонув в ресурсах (например, можно взять RepVGG на меньшем датасете) и согласуете в табличке

   https://docs.google.com/spreadsheets/d/1fX8LBZ5rKeKC-1NyN-ZMojDjccoBHX-UKOrsSdQSCb8/edit?usp=sharing

3) Повторяете статью, делаете свои дополнительные эксперименты (сравнение дополнительных архитектур, добавление новых моделей и тд) в количестве не менее 3, но лучше больше (надежда, что один эксп длится <=8 часов). В исключительных случаях допускается 2 эксперимента.
4) Пишете отчет на английском (4-5 страниц в 2 колонки)/русском (5-6 страниц в силу особенностей языка), делаете репозиторий с кодом хорошего качества
5) Можно использовать код от авторов статьи, но за его качество отвечать начинаете тоже вы. Кроме того, от вас требуется обеспечить запуск на питоне не ниже 3.11 и PyTorch 2.0.
6) Одна тема может быть только у 2 команд. Но код при этом должен быть разным (если не от авторов)

Дедлайн: 27.03.2026 23:59.