


Трекинг, Id, сегментация

Марк Блуменау


Что такое трекинг?



С чем работаем?




Чего добиваемся?



Typical Object
Detection Algorithm

Vs.




Typical Object
Tracking Algorithm


Results (output)

Почему это сложно?

- 1) Скорость работы :)
- 2) Фон бывает разный и даже изменяющийся
- 3) Перспектива (человек далеко и человек близко сильно разных размеров)
- 4) Один объект закрыл другой




Спорт - это жизнь! И ад одновременно.



[GitHub - deshwalmahesh/yolov7-deepsort-tracking](https://github.com/deshwalmahesh/yolov7-deepsort-tracking): Modular and ready to deploy code to detect and track videos using YOLO-v7 and DeepSORT

Как оценить качество? HOTA



HOTA

$$\text{LocA} = \frac{1}{|\text{TP}|} \sum_{c \in \text{TP}} \text{Loc-IoU}(c)$$

$$\text{DetA} = \text{Det-IoU} = \frac{|\text{TP}|}{|\text{TP}| + |\text{FN}| + |\text{FP}|}$$

$$\text{Ass-IoU} = \frac{|\text{TPA}|}{|\text{TPA}| + |\text{FNA}| + |\text{FPA}|}$$


$$\text{AssA} = \frac{1}{|\text{TP}|} \sum_{c \in \text{TP}} \text{Ass-IoU}(c)$$

$$= \frac{1}{|\text{TP}|} \sum_{c \in \text{TP}} \frac{|\text{TPA}(c)|}{|\text{TPA}(c)| + |\text{FNA}(c)| + |\text{FPA}(c)|}$$

Все еще HOTA


$$\begin{aligned} \text{HOTA}_{\alpha} &= \sqrt{\text{Det}A_{\alpha} \cdot \text{Ass}A_{\alpha}} \\ &= \sqrt{\frac{\sum_{c \in \text{TP}_{\alpha}} \text{Ass-IoU}_{\alpha}(c)}{|\text{TP}_{\alpha}| + |\text{FN}_{\alpha}| + |\text{FP}_{\alpha}|}} \\ \text{HOTA} &= \int_{0 < \alpha \leq 1} \text{HOTA}_{\alpha} \\ &\approx \frac{1}{19} \sum_{\substack{\alpha=0.05 \\ \alpha+=0.05}}^{0.95} \text{HOTA}_{\alpha} \end{aligned}$$

А можно картинку?



[How to evaluate tracking with the HOTA metrics - Autonomous Vision Blog](https://arxiv.org/abs/2009.07736)

Компоненты трекинга




Идентификация или почему не классификация

Labeled Faces in the Wild

Около 13 000 фоток на около 6000 людей



Классическое CV рулит! (DeepFace)



DeepFace

Обучаем некоторую архитектуру для классификации (число классов = число людей в данных)


Используем выходы предпоследнего слоя как признаковое описание изображения

Признаки нормализуются (чтобы норма была единичной)


Считаем близость векторов по какой-нибудь метрике

FaceNet

А давайте похожие люди сразу рядом будут?



TripletLoss



$$\sum_i^N \left[\|f(x_i^a) - f(x_i^p)\|_2^2 - \|f(x_i^a) - f(x_i^n)\|_2^2 + \alpha \right]_+$$

Сегментация


Что это?



(a) Image



(b) Semantic Segmentation



(c) Instance Segmentation



(d) Panoptic Segmentation

Metrics

Попиксельный Accuracy:

$$L(y, a) = \frac{1}{n} \sum_{i=1}^n [y_i = a_i]$$

Jaccard:

$$J_k(y, a) = \frac{\sum_{i=1}^n [y_i = k][a_i = k]}{\sum_{i=1}^n \max([y_i = k], [a_i = k])}$$

Loss


Categorical cross-entropy

$$L(y, a) = \sum_{i=1}^n \sum_{k=1}^K [y_i = k] \log a_{ik}$$


где (softmax):

$$a_{ik} = \frac{\exp(b_{ik})}{\sum_{m=1}^K \exp(b_{im})}$$


База (UNet)




А как раздувать?



Раздуваем хитро



Результаты



Mask RCNN






Figure 1. The **Mask R-CNN** framework for instance segmentation.

Чуть подробнее



Результаты



<https://arxiv.org/pdf/1703.06870>